

分类号：
U D C:

密级：
学号：418000220020

南昌大学专业学位硕士研究生
学 位 论 文

基于呼吸信号的阻塞性睡眠呼吸暂停识别研究
Research on Obstructive Sleep Apnea Recognition Based on
Respiratory Signal

徐诚

培养单位（院、系）：软件学院

指导教师姓名、职称：夏灵林、副教授

指导教师姓名、职称：

专业学位种类：电子信息硕士

专业领域名称：软件工程

论文答辩日期：2025 年 5 月 16 日

答辩委员会主席：熊邦书

评阅人：

2025 年 5 月 30 日

一、学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的
研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含
其他人已经发表或撰写过的研究成果，也不包含为获得南昌大学或其他教育机
构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡
献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名（手写）：徐诚 签字日期：2025 年 5 月 30 日

二、学位论文版权使用授权书

本学位论文作者完全了解南昌大学有关保留、使用学位论文的规定，同意
学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文
被查阅和借阅。本人授权南昌大学可以将学位论文的全部或部分内容编入有关
数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编本学位论
文。同时授权北京万方数据股份有限公司和中国学术期刊（光盘版）电子杂志
社将本学位论文收录到《中国学位论文全文数据库》和《中国优秀博硕士学位
论文全文数据库》中全文发表，并通过网络向社会公众提供信息服务，同意按
“章程”规定享受相关权益。

学位论文作者签名（手写）：徐诚 导师签名（手写）：夏美林

签字日期：2025 年 5 月 30 日 签字日期：2025 年 5 月 30 日

论文题目	基于呼吸信号的阻塞性睡眠呼吸暂停识别研究				
姓 名	徐诚	学号	418000220020	论文级别	博士 ☐ 硕士 ☒
院/系/所	软件学院		专业	软件工程	
备注：					

☒公开 ☐保密（向校学位办申请获批准为“保密”，_____年____月后公开）

摘 要

阻塞性睡眠呼吸暂停（Obstructive Sleep Apnea, OSA）是一种普遍存在的睡眠呼吸问题，会对人体造成严重损害。尽管多导睡眠监测（Polysomnography, PSG）被视为诊断 OSA 的金标准，但其复杂且费用较高。因此，寻找简便、经济的识别与分类方法具有重要意义。本文提出一种新的 OSA 识别和分类方法，即通过自动检测睡眠呼吸暂停和低通气事件（Apnea Hypopnea Events, AHE）的持续时间，根据整夜睡眠呼吸的声音信号计算出 AHE 持续时间与总睡眠时间的比值，判别患者是否患有 OSA 以及其严重程度，为研制简易的诊断和分级设备奠定基础。本文主要研究内容如下：

（1）高质量降噪滤波。有效去除噪声在 OSA 的准确识别和分类中是关键前提。本文比较了谱减法、维纳滤波和卡尔曼滤波算法在信号降噪中的不足，设计了一种基于预加重、分帧加窗、小波变换和非线性变换等多技术融合的滤波降噪算法，能显著去除噪声，实现真实睡眠呼吸声音信号的有效提取。

（2）睡眠呼吸声音信号分割。精准分割信号中每次 AHE 的发生起止时间点对进一步分析和诊断 OSA 至关重要。本文设计了一种 FM-DS-U-Net 网络用于实现信号的分割。运用该网络对 36 例患者整晚睡眠呼吸声音进行分割测试，在重度患者中，所设计的网络在 F1 值、敏感度和阳性预测率中分别达到了平均 92.04%、92.37%、90.85% 的效果，表现出优异的分割性能。

（3）AHE 参数的识别研究和应用。合理的 AHE 分级参数能提高模型分类精度，帮助临床医生评估 OSA 严重程度并制定个性化治疗方案。本文设计了一种新量化参数 S 值，即 AHE 持续时间占总睡眠时间的比值。首先，通过分析 225 例 PSG 数据验证 S 值在 OSA 诊断中的有效性，S 值在评估 OSA 的准确率达到 99.56%，且在重度、中度、轻度、正常的准确率分别为 96.09%、89.19%、91.49% 和 98.89%。其次，采用 11 例符合标准且未经处理的睡眠呼吸声音验证 FM-DS-U-Net 网络对 AHE 持续时间的识别能力，并通过 S 值评估 OSA 的严重程度，评估结果与 PSG 结果高度一致，在重度患者的分类中效果显著。

综上，通过对信号进行高质量降噪滤波、分割及 AHE 参数识别研究和应用实验，证实了呼吸信号在诊断 OSA 上的有效性，能够用于 OSA 的识别与分类。

关键词：OSA；睡眠呼吸声音；信号分割；AHE 持续时间；识别与分类

ABSTRACT

Obstructive sleep apnea (OSA) is a common sleep breathing problem that can cause serious damage to the human body. Although polysomnography (PSG) is regarded as the gold standard for the diagnosis of OSA, it is complex and expensive. Therefore, it is of great significance to find a simple and economical identification and classification method. In this paper, a new OSA identification and classification method is proposed. By automatically detecting the duration of sleep apnea and hypopnea events (AHE), the ratio of AHE duration to total sleep time is calculated according to the sound signal of sleep breathing throughout the night, and the subjects are judged whether they have OSA and its severity, which lays a foundation for the development of simple diagnostic and grading equipment. The main research contents of this paper are as follows :

(1) High quality noise reduction filtering. Effective noise removal is a key prerequisite for accurate identification and classification of OSA. In this paper, the shortcomings of spectral subtraction, Wiener filtering and Kalman filtering algorithms in signal noise reduction are compared. A filtering and noise reduction algorithm based on multi-technology fusion of pre-emphasis, framing and windowing, wavelet transform and nonlinear transform is designed, which can significantly remove noise and realize the effective extraction of real sleep breathing sound signals.

(2) Sleep breathing sound signal segmentation. Accurate segmentation of the starting and ending time points of each AHE in the signal is crucial for further analysis and diagnosis of OSA. In this paper, an FM-DS-U-Net network is designed to realize signal segmentation. The network was used to segment the sleep breathing sounds of 36 patients throughout the night. In severe patients, the designed network achieved an average of 92.04%, 92.37%, and 90.85% in F1 value, sensitivity, and positive predictive rate, respectively, showing excellent segmentation performance.

(3) Research and application of AHE parameter identification. Reasonable AHE grading parameters can improve the classification accuracy of the model and

help clinicians to evaluate the severity of OSA and formulate personalized treatment plans. In this paper, a new quantitative parameter S value is designed, that is, the ratio of AHE duration to total sleep time. Firstly, the validity of S value in the diagnosis of OSA was verified by analyzing 225 PSG data. The accuracy of S value in evaluating OSA reached 99.56%, and the accuracy in severe, moderate, mild and normal was 96.09%, 89.19%, 91.49% and 98.89%, respectively. Secondly, 11 standard and untreated sleep breathing sounds were used to verify the recognition ability of FM-DS-U-Net network to AHE duration, and the severity of OSA was evaluated by S value. The evaluation results were highly consistent with PSG results, and the effect was significant in the classification of severe patients.

In summary, through the research and application experiments of high-quality noise reduction filtering, segmentation and AHE parameter identification of the signal, the effectiveness of the respiratory signal in the diagnosis of OSA is confirmed, which can be used for the identification and classification of OSA.

Key words : OSA; Sleep breathing sound; Signal segmentation; AHE duration; Identification and classification

目 录

第 1 章 引言	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 不同生理信号识别 OSA 研究现状	3
1.2.2 睡眠呼吸声音信号识别 OSA 研究现状	5
1.2.3 OSA 评估指标研究现状	6
1.3 论文主要研究内容、目标及结构安排	7
1.3.1 主要研究内容	7
1.3.2 研究目标	9
1.3.3 结构安排	9
第 2 章 睡眠呼吸声音相关理论与数据预处理	10
2.1 睡眠呼吸声音与 OSA 病理关系	10
2.2 OSA 诊断标准	11
2.3 睡眠呼吸声音数据集的构建	12
2.3.1 数据采集	12
2.3.2 数据清洗	13
2.3.3 数据切割	14
2.3.4 数据集构建	15
2.4 睡眠呼吸声音的滤波降噪	16
2.4.1 问题描述	16
2.4.2 数据格式转换	17
2.4.3 常用滤波降噪算法实现	17
2.4.4 基于多技术融合的滤波降噪算法实现	21
2.5 本章小结	26
第 3 章 睡眠呼吸声音信号分割	27

3.1 基于 FM-DS-U-Net 的分割网络	27
3.1.1 问题描述与设计思路	27
3.1.2 技术分析	28
3.1.3 FM-DS-U-Net 网络设计实现	32
3.2 实验与分析	35
3.2.1 实验环境	35
3.2.2 实验设计与数据集准备	35
3.2.3 参数设置	37
3.2.4 评估指标	37
3.2.5 实验预测结果	38
3.2.6 误差容忍度对实验结果的影响	39
3.3 实验结果分析	42
3.4 本章小结	43
第 4 章 AHE 参数的识别研究和应用	44
4.1 AHE 持续时间评估 OSA 严重程度	44
4.1.1 AHE 持续时间识别	44
4.1.2 AHE 持续时间占比参数 S	45
4.2 实验与分析	46
4.2.1 实验设计与数据集准备	46
4.2.2 S 值参数的有效性对比	48
4.2.3 S 值的应用测试	50
4.2.4 基于睡眠呼吸声音的 S 值有效性分析	52
4.3 实验结果分析	54
4.4 讨论	55
4.5 本章小结	55
第 5 章 总结与展望	57
5.1 总结	57
5.2 展望	58
致 谢	60

目录

参考文献.....	61
攻读学位期间的研究成果.....	67

第 1 章 引言

1.1 研究背景及意义

睡眠是人类生活中的重要生物现象，占据了整个生命周期的三分之一^[1]。保持规律且高质量的睡眠对健康至关重要，但由于时代变迁、环境变化和工作压力，许多人常忽视自身睡眠障碍的存在。阻塞性睡眠呼吸暂停（Obstructive Sleep Apnea, OSA）作为一种普遍存在的睡眠障碍疾病，其主要特征是在睡眠中上气道反复塌陷和阻塞，导致呼吸暂停或通气不足^[2,3]，进而导致频繁发生低氧血症。据调查统计，OSA 的发病率达到 4%~30%^[2]。全球 30-69 岁人群中 9.36 亿罹患该病，其中中国患病人数约为 1.76 亿，位居全球第一^[4]，该病对人体会产生多系统损害，严重的情况下会增加心脑血管疾病^[5-8]、代谢综合征^[9,10]、神经血管疾病^[11]以及执行功能和记忆方面的认知功能障碍等的患病风险，已成为全球性健康问题。

在 OSA 的筛查研究方面，传统医学诊断通常依赖于针对性的临床检测和指标判读，多导睡眠监测（Polysomnography, PSG）被广泛认可为诊断 OSA 的标准^[12]，也是 OSA 诊断的常用工具，但其复杂性和高昂成本限制了其在初步诊断中的广泛应用，结合中国高患病率的需求，迫切需要探索更灵活、简便、经济、迅速的 OSA 识别与分类方法。目前，国际上通常采用呼吸暂停-低通气指数（Apnea Hypopnea Index, AHI）来分级 OSA 的严重程度，AHI 是整夜睡眠中每小时内发生的呼吸暂停和低通气事件（Apnea Hypopnea Events, AHE）的平均次数^[13]，可直接从 PSG 数据上获取。参照美国睡眠医学会^[14]和 ICSD-3 指南的指导规则^[15]，当 AHI 指数小于 5 时，表明正常睡眠呼吸状态；当 AHI 指数大于 5 时表明患有 OSA 病症。由于 PSG 在诊断 OSA 的过程中，需要对多个生理信号参数进行监测和记录，包括脑电图、眼动图、心电图、鼻压力传感器、口鼻温度气流、胸腹部呼吸运动、鼾声、血氧饱和度、体位、腿动等，同时配备高倍红外摄像机，高度灵敏的双向对讲系统对病床进行实时监控，是睡眠医学研究和睡眠疾病诊断的基本工具，是诊断 OSA、评估其严重程度的标准方法。PSG 由专业技术人员操作，具备较高的诊断准确性和较低的失败率。但其对设备、检查环境要求较为苛刻，采集和判读技术复杂，等候监测时间较长，费用相对

昂贵，且多数基层医院未普及 PSG 监测，应用受到一定的限制。同时，由于传感器连接复杂，患者容易出现“首夜效应”，干扰患者正常睡眠。因此，开发一种简便、经济且快速的识别与分类方法，以替代 PSG 进行 OSA 的初步诊断，具有重要意义。此举不仅能降低医院人力和设备成本，还能缩短患者等待检查时间，减轻患者的经济负担，使检查结果更符合患者实际的睡眠状况。

此外，在 OSA 的分级诊断研究方面，大多数研究仍然依赖传统的 AHI 值来最终确定患者的严重程度，AHI 值主要关注 AHE 的次数，却忽略了 AHE 的持续时间（AHI 与 AHE 之间的关系如图 1.1 所示），而这一关键参数在评估 OSA 患者的临床影响时具有重要意义。OSA 的临床影响被普遍认为与 AHE 引发的周期性低氧血症有关，而 AHI 的计算方法是假定所有超过阈值的 AHE 具有相同的重要性，如 10 秒和 70 秒的呼吸暂停在评估 OSA 严重程度时被视为等同，这显然与临床表现不符。事实上，AHE 的持续时间会对血氧饱和度产生明显影响，持续时间越长，血氧饱和度下降越严重^[16-18]，而间歇性低氧血症是 OSA 继发全身多系统损害的重要因素。因此，AHE 的持续时间对于纳入评估 OSA 病情的严重程度以及对全身多系统功能损害非常重要。




图 1.1 AHI 与 AHE 关系

综上，就当前临床针对 OSA 的筛查方法和分级诊断研究中存在的不足，本文结合临床实际，在 OSA 的筛查方法上，通过高质量的信号滤波降噪，去除噪声并增强信号的关键特征，在不干扰睡眠的情况下采集高质量的睡眠呼吸信号，并对其进行实时监测与分析，完成睡眠呼吸声音的获取和验证，为 OSA 的识别与分类提供了便捷且低成本的可行性方案；在 OSA 识别诊断的研究中，设计一种与睡眠呼吸声音信号相适应的网络架构，结合深度学习技术，构建 AHE 信号起始和结束特征的识别模型，并进一步提出新的分级诊断参数，实现 OSA 的分级诊断，为研制简易的诊断和分级设备奠定基础。

1.2 国内外研究现状

1.2.1 不同生理信号识别 OSA 研究现状

在简化传统 OSA 诊断流程的研究中。国内外许多研究者尝试从临床数据和 PSG 检测的多种信号中，选择几个甚至一个关键信号（如气流、血氧饱和度、心电和脑电信号）来辅助 OSA 诊断。这些信号在监测 AHE 发生方面具有较为明显的特点。此外，一些研究还使用了鼻塞压力信号、人体体征数据和问卷等方式。这些方法通过不同的技术和手段为 OSA 的诊断和分型提供了重要参考。具体如下：

（1）气流信号

气流信号能够直接反映呼吸过程中气流的变化，有助于识别患者是否存在呼吸暂停或呼吸浅表等情况，这是 OSA 的主要特征之一。例如，Yue 等人^[19]基于鼻气流的多分辨率残差网络建立了深度学习模型，用于 OSA 的诊断和分类，准确率达到 90.8%。Jin 等人^[20]提出了一种基于鼻腔气流的筛查设备，能够进行呼吸节律检测和 OSA 筛查测试，该设备配备了微机电系统传感器用于测量鼻腔气流，并包含时域信号处理 IC 芯片用于呼吸暂停检测和自主评分，其特异度可达到 90.0%。此外，Barroso 等人^[21]通过离散小波变换提取气流信号相关特征，结合快速相关滤波器进行特征选择，并应用自适应增强集成学习和贝叶斯多层感知器神经网络进行分类与回归，最终诊断准确率达到 90.99%。

（2）血氧饱和度信号

患有 OSA 症状的人群在睡眠过程中因呼吸暂停或气流受限导致氧气摄入不足，从而引起血氧饱和度下降，监测血氧变化有助于识别 AHE 的发生。例如，Garde 等人^[22]记录脉搏血氧饱和度和脉冲峰值间隔，分析动态变化，采用贝叶斯信息准则选择特征并设定 AHI 阈值，设计了多元逻辑回归模型识别 OSA 患者病情严重程度，取得了良好效果。与此同时，Villar 等人^[23]则采用卷积神经网络（Convolutional Neural Networks, CNN）评估血氧饱和度信号中 AHE 的发生数量，并通过贝叶斯优化调整 CNN 模型，能精准识别出 OSA 患者。Alarez 等人^[24]针对夜间血氧饱和度信号进行非线性分析，通过中心趋势度量和二阶差分图检测变异性，Lempel-Ziv 复杂度检测复杂性，前者敏感性和特异性得出 90.1%、82.9%，后者 86.5%、77.6%。此外，Park 等人^[25]则设计出一种基于光电容积描记图结合血氧饱和度信号的 AHE 分类方法，他们通过对睡眠状态和睡眠呼吸障碍严重程度的分析，成功将 AHE 进行分类，其敏感性和阳性预测值分别达到 92.4%

和 92.8%。

（3）心电信号

心电信号主要通过分析心率变异性，结合 AHE 数据，揭示交感神经活动增强和副交感神经活动减弱的情况，从而辅助诊断 OSA 并评估其严重程度。例如，Li 等人^[26]采用稀疏自编码技术对心电信号进行特征提取，同时结合支持向量机有效地检测出 OSA 病情。Haifa 等人^[27]通过输入原始心电信号，运用深度学习技术自动挖掘心电图与 AHE 之间的潜在关系特征，取得了显著效果。Sharan 等人^[28]设计了一种带残差连接的 CNN，直接从原始心电信号中学习特征进行分类，效果显示良好。Jarchi 等人^[29]则通过熵和统计矩提取肌电图特征，结合同步挤压小波变换和深度学习算法对心率相关特征进行提取，结果显示，在 OSA 患者的分类中取得了较高的准确性。

（4）脑电信号

脑电信号是一种记录大脑电活动的工具，能够反映大脑在不同睡眠阶段的电活动特征。在 OSA 患者的睡眠过程中，AHE 的发生会显著影响睡眠的质量和结构，进而改变大脑的电活动模式。通过对脑电信号的分析，可以有效地检测到 AHE 的发生。例如，Bello 等人^[30]通过脑电信号识别 AHE 的发生，使用 K 最近邻分类器（K-Nearest Neighbors, KNN）实现了 85.92% 的灵敏度、80% 的特异度和 82.69% 的准确度。Suvasish 等人^[31]则采用多频段脑电信号以获得带间能量比特征的方式，运用 KNN 对是否存在 AHE 发生的信号分类，其准确率、特异度和敏感性分别达到了 92.21%、94.04% 和 90.39%。

（5）其他信号

在 OSA 的诊断领域，还存在多种其他信号和方法被提出用于识别和诊断 OSA。例如，Wang 等人^[32]提出了一种将人体测量学和问卷数据相结合的方法对 OSA 病情进行检测，通过决策树预测 AHE 发生的模式，以此分类 OSA 的严重程度，诊断准确率可达到 81.82%。吕等人^[33]通过对腹部信号进行处理，提取信号的时频域相关特征，并采用随机森林对 AHE 的发生进行检测，结果也表明检测准确率较好。

这些所使用的信号方法为 OSA 的诊断和分级提供了重要的参考。尽管这些方法在诊断方面取得了进展，但大多数研究中所采用的检测信号都很难获取，且这些信号的采集过程对仪器设备和所需的监测环境有着严格的要求，并不足以实现家庭化使用。相比之下，睡眠呼吸声音信号采集简便、成本低廉、无需

复杂设备，既能为 OSA 诊断提供新视角，又具备在家庭中便捷监测的潜力，提升了早期诊断和长期监测的可行性。

1.2.2 睡眠呼吸声音信号识别 OSA 研究现状

由于呼吸系统与 OSA 密切相关。相关研究指出，患者的睡眠呼吸声音，包括打鼾声和呼吸声，可能包含上呼吸道的重要信息^[34,35]。Wei^[36]的研究也表明，OSA 患者的腭咽和舌咽部阻塞会改变共鸣腔的大小和形状，从而影响声音质量，并导致上呼吸道结构异常在主观和声学特性上产生变化。鉴于此，利用睡眠呼吸声音信号评估 OSA 严重程度具有较高的可行性，且记录此信号不干扰睡眠，可在各种设备中进行。此举可降低医院成本、缩短患者等待时间、减轻经济负担，并提供更符合实际睡眠状况的检查结果，具有良好的应用前景。

例如，候等人^[37]提出了一种名为鼾声子带能量对比度的新型特征，并通过这一特征去验证是否能以鼾声信号声学特性对 OSA 导致的阻塞情况进行预测，结果也表明预测效果显著。Kim 等人^[38]通过计算鼾声相关的多个参数，如鼾声百分比、时间指数、平均持续时间和最长打鼾时间大小，并以这些参数去深入分析与 OSA 严重度之间的关系，研究结果显示这些参数可以预测出 OSA 病情。李等人^[39]采用短时傅里叶变换计算声音信号中不同频段的能量，从而识别出鼾声段并用于判别 OSA 病情。Luo 等人^[40]设计一种基于深度特征转移的 OSA 检测方法，通过训练深度卷积神经网络区分呼吸声与噪声，并应用逻辑回归分类器识别 OSA，取得了良好的效果。Cheng 等人^[41]则使用长短期记忆网络对 OSA 和正常打鼾进行分类，准确率达到 95.3%。Zhao 等人^[42]设计了一种频谱划分方法，通过分析呼吸声音频谱进而提取相关能量特征，最后采用支持向量机分类不同呼吸声音状态，以此辅助诊断 OSA 的效果良好。Song 等人^[43]提出了一种基于鼾声分类和融合模型的 AHI 评估方法，结果也表明，该方法可对 OSA 病情进行有效诊断。Lim 等人^[44]的研究对患者睡眠呼吸声音信号中的相关参数进行了提取，如过零率、短时傅里叶变换和梅尔频率倒谱系数等，最后结合循环神经网络对信号进行鼾声检测，准确率达到 98.9%。Nguyen 等人^[45]则记录了 15 名患者的整晚睡眠呼吸声音，设计出了一种与之相关的多层感知器神经网络，对信号中的鼾声检测准确率达到 96%。Xie 等人^[46]的研究通过量化鼾声率变异性和能量趋势的时间变化，将患者生理信息与特征相结合，从而对 OSA 进行诊断。Hayashi

等人^[47]则提出了一种新型特征，将鼾声发作前一小时 AHE 的发生次数用于检测 OSA 有关的鼾声，效果显著。杨等人^[48]研究了不同严重程度 OSA 的患者鼾声表现情况，计算了鼾声的最大频率、峰频率和平均频率等。研究结果表明，不同严重程度 OSA 患者鼾声也存在一定差别，因此可以通过鼾声特征对 OSA 的严重程度进行分级。Kim 等人^[49]的研究则提取了整晚睡眠呼吸信号中的音频特征，选取了显著的特征作为声学生物标志物，并使用支持向量机和神经网络进行分类，达到了 92.5% 的准确率。Akyol 等人^[50]结合梅尔频率倒谱系数、黑体谱图和色谱图等特征，利用改进的灰狼优化算法和 BO 优化器更新模型参数，实现了声音片段的有效分类。Romero 等人^[51]通过记录处于家庭环境下产生的睡眠呼吸声音信号，设计了一种基于深度神经网络噪声筛查的方法对信号进行 OSA 自动检测。

目前，利用睡眠呼吸声音信号进行 OSA 检测已经取得了一定的进展，该方法能够有效捕捉到与 OSA 相关的多种特征信息。因此，采用睡眠呼吸声音信号进行 OSA 识别具有可行性，未来可能成为 OSA 诊断的一种便捷且成本效益高的方法。然而，现有研究中，噪声干扰和呼吸特征的个体差异仍然是一个挑战。

1.2.3 OSA 评估指标研究现状

在评估是否患有 OSA 病症及其严重程度的指标参数中。目前最常用的仍是 AHI 参数。该参数通过统计每小时 AHE 发生的平均次数，广泛用于临床诊断和治疗效果评估中。然而，AHI 参数在诊断 OSA 上可能受多因素的影响，包括评估方法、评分标准和评价者的专业水平。尽管国际上普遍采用 AHI 值大于 5 作为评估是否患有 OSA 的标准，但该标准却未考虑不同持续时间（如 10 秒与 70 秒）的 AHE 在临床中的差异，而是将所有超过阈值的 AHE 视为同等重要。因此，在评估病情严重度和预测远期并发症等方面，这一标准逐渐暴露出局限性。

近年来，相关人员也逐渐意识到，除了 AHI 外，AHE 的持续时间等因素也应纳入 OSA 评估中，以提供更全面的疾病评估。Asli 等人^[52]和 Zamzil 等人^[53]认为，AHE 持续时间或许能更准确地评估 OSA 的严重程度。Sarac 等人^[54]也指出，与 AHE 时间较短的 OSA 患者相比，AHE 平均时间较长的患者所受到的负面影响更为显著。睡眠心脏健康研究^[55]的数据同样表明，短事件持续时间与高全因死亡率相关。此外，有研究者^[56]指出，目前关于 OSA 预后的流行病学工作

主要聚焦在 AHI，但单独依赖 AHI 可能无法全面捕获病理生理过程，也无法反映低氧性负担、睡眠中的周期性肢体运动与不良心血管事件的发生有关，它只代表 PSG 生理数据的一小部分。AHE 持续时间会对血氧饱和度产生明显影响，持续时间越长，血氧饱和度下降越严重^[16-18]，而间歇性低氧血症是 OSA 继发全身多系统损害的重要因素。患者整晚 AHE 发生的总持续时长与 OSA 症状和严重程度有很大的相关性^[57,58]。也有研究发现，OSA 患者经过相关专业治疗后，症状得到改善但 AHI 值并未有明显改变^[59,60]。

综上，AHE 持续时间可能是评估 OSA 严重程度时应重点关注的指标。AHE 的持续时间对于纳入评估 OSA 病情的严重程度以及对全身多系统功能损害非常重要。然而，目前睡眠领域针对此方面的研究比较欠缺。通过开发现有的和新兴的分析方法，PSG 新参数可能为 OSA 的个性化管理提供一条新途径^[61]。因此，本文通过分析 AHE 持续时间与 OSA 病情的相关性，旨在为 OSA 病情的评估提供更多参考标准。

1.3 论文主要研究内容、目标及结构安排

1.3.1 主要研究内容

以患者的睡眠呼吸声音信号为研究对象，进一步采集和处理数据，构建相应的 AHE 网络识别模型，进而探索 AHE 相关评估参数的研究和应用，实现睡眠呼吸声音信号的 AHE 自动识别分割，并以此诊断 OSA 严重程度。本文主要研究内容逻辑关系如图 1.2 所示。具体如下：

（1）睡眠呼吸声音信号的高质量滤波降噪处理

睡眠呼吸声音通常伴随环境噪声和异常信号的干扰，导致 AHE 误判时有发生，不同人群的呼吸声音的差异性问题等也影响了滤波方法的有效性和筛查方法的实用性。如何完成信号的高质量滤波降噪，实现干扰的抑制和 OSA 特征的增强保持是本文的主要研究内容之一。无干扰的信号不仅有助于加速信号处理过程，提高诊断效率，还能显著提升后续模型的分割精度。


（2）睡眠呼吸声音信号分割

OSA 的诊断受到个体差异的影响，如何在保持高分辨率和准确性的同时，构建有效的特征识别模型，精确地分割睡眠呼吸声音信号中的每次 AHE 发生时

(3) AHE 参数的识别研究和应用

本文结合计算机科学、人工智能、神经科学和临床医学等多学科，聚焦国际前沿的基础科学问题，并紧密结合呼吸类疾病早期诊断与干预的重大需求。其创新体现在以下几个方面：

(2) 结果客观可信, AHE 持续时间与 OSA 病理生理机制密切相关, 新参数-AHE 的持续时间可实现参数的客观量化, 对后续的研究有一定的参考价值。



1.3.2 研究目标

关注 AHE 信号的特征，通过睡眠呼吸声音信号的高质量滤波降噪算法的实验研究，进一步完善 OSA 的简易筛查方法；通过 AHE 分类识别模型及评估参数的探索研究，构建有效的分级诊断模型，并为临床提供 OSA 早期诊断和自动干预诊断的技术手段。

1.3.3 结构安排

本文共包括五个章节，具体安排如下：

第一章：引言。首先阐述了本文的研究背景及意义，强调了睡眠呼吸声音信号在识别和分级 OSA 病症上的重要意义；接着梳理了国内外相关领域研究现状；最后概括了本文的主要研究内容、目标和结构安排。

第二章：睡眠呼吸声音相关理论与数据预处理。介绍了睡眠呼吸声音与 OSA 病理之间关系以及睡眠呼吸声音数据的采集、来源和构建，并且详细阐述了本文所使用的睡眠呼吸声音数据的滤波降噪过程。

第三章：睡眠呼吸声音信号分割。本章在第二章的基础上，针对睡眠呼吸声音信号的特征，设计了相应的 AHE 识别网络并进行训练和测试，利用患者数据对模型进行验证和不断优化，得出相关实验结果，并对这些结果进行了深入分析。

第四章：AHE 参数的识别研究和应用。本章基于患者的睡眠呼吸声音信号数据，结合第三章所训练的模型，评估并预测 AHE 的持续时间。提出了一种基于 AHE 总持续时间比例（参数 S）诊断和分类 OSA 的方法。详细介绍了 AHE 持续时间的提取流程及实验参数设置，重点比较了基于 PSG 诊断的参数 S 值与睡眠呼吸声音信号中的参数 S 值及传统 AHI 值之间的相关性。最后，对实验预测结果进行了讨论与分析。

第五章：总结与展望。总结了本文的研究内容、所做的工作和得出的结果，最后分析了整个过程当中存在的不足，并对下一阶段的工作进行了展望。

第 2 章 睡眠呼吸声音相关理论与数据预处理

本章探讨了睡眠呼吸声音与 OSA 病理的关系、PSG 设备在 OSA 诊断中的应用及 AHI 指数的量化。同时，讨论了数据集构建和信号滤波降噪过程，分析了常用降噪算法在处理复杂环境下睡眠呼吸声音信号的不足。重点研究了一种多技术融合的滤波降噪算法，以实现在复杂环境下依然保持高准确率和良好鲁棒性。本章的信号处理过程有助于提高后续 OSA 诊断效率，为后续模型的分割精度提供保障。

2.1 睡眠呼吸声音与 OSA 病理关系

睡眠呼吸声音之所以能够帮助诊断和识别 OSA 病症，关键在于这些声音信号能够反映出呼吸过程中的生理变化，特别是与气道阻塞相关的异常情况。OSA 是由于上气道在睡眠过程中部分或完全阻塞所引起的，导致气流受限或中断，从而使得正常的呼吸过程发生紊乱。通过对呼吸过程中产生的声音信号进行分析，可以有效反映气道的健康状况，从而帮助识别出 OSA 病症的特征性表现。如图 2.1 展示了不同状态下的气道变化结构。




图 2.1 气道变化对比

首先，OSA 患者在发生气道阻塞时，会伴随着一系列的声音变化。例如打

鼾、喘息、呼吸暂停期间的沉默和气流恢复时的喘息声等。当上气道发生阻塞时，气流无法顺利进入肺部，气道的收缩和变窄会引发震动，进而产生不同的声音。打鼾声则通常由部分气道狭窄或振动引起，是 OSA 的常见前兆。

其次，呼吸过程中声波的产生与气道的物理状态密切相关。当上气道发生部分阻塞时，气流在通过时会经历不同的压力变化和速度变化，这些变化会导致声波的频率、强度和波形发生变化。例如，杨等人^[48]通过提取不同 OSA 程度患者的鼾声信号，进而对鼾声最大频率，峰频率以及平均频率等特征进行计算，证明了 OSA 严重程度不同的患者产生的鼾声有一定的差别。

最后，通过对这些声音信号的分析，可以揭示出一些生理机制。气道的塌陷通常是非完全的，有时可能是暂时的，这种不完全的阻塞会导致呼吸的不规则性和声音的变化。通过长期观察这些呼吸声音的变化，可以揭示出阻塞发生的频率、持续时间以及恢复的过程，从而为 OSA 的识别和分级提供线索。睡眠呼吸声音信号能够反映出这一过程的时序性特征，即阻塞的开始、持续以及气道的恢复，从而为临床医生提供重要的参考依据。

综上，睡眠呼吸声音信号之所以能够识别与分类 OSA 病症，是因为它们能够真实反映出气道在睡眠中的动态变化，尤其是气道阻塞的发生与恢复过程。通过分析这些声音信号的变化规律，可以揭示出与 OSA 相关的生理特征，从而为 OSA 的识别与分类提供有效的信息。

2.2 OSA 诊断标准

PSG 检测需要在专门的睡眠环境下进行，通过监测多个生理信号，同时配备高倍红外摄像机，高度灵敏的双向对讲系统对病床进行实时监控，是睡眠医学研究和睡眠疾病诊断的基本工具和诊断 OSA 的金标准。

PSG 通过对一整夜的检测数据分析，计算出 AHE 总次数，从而得出 AHI 值，并根据此值对 OSA 的严重程度进行判定。AHE 发生的相关判读标准如下：

(1) 呼吸暂停判读标准：气流波形下降超过正常水平的 90%；降低时长持续 10s 以上。

(2) 低通气判读标准：气流波形下降超过正常水平的 30%；血氧饱和度下降；降低时长持续 10s 以上。

参照美国睡眠医学会和 ICSD-3 指南的指导规则^[14,15]，对 OSA 病情的评判

标准进行定义，如下表 2.1 所示。

表 2.1 OSA 判读标准

参数	正常人群	轻度OSA患者	中度OSA患者	重度OSA患者
AHI（次/小时）	$AHI < 5$	$5 \leq AHI < 15$	$15 \leq AHI < 30$	$AHI \geq 30$

由于 PSG 对设备和环境要求高，技术复杂且费用昂贵，且多数基层医院尚未普及，导致其应用受限，受众较少。

2.3 睡眠呼吸声音数据集的构建

至今，通过睡眠呼吸声音信号分析 OSA 的研究仍为新兴领域，目前尚无标准公共数据集供研究使用。本文实验数据来源于实验室与附属医院的合作，且在患者同意下采集。

2.3.1 数据采集

本次研究中的数据采集于 2020 年 9 月至 2024 年 10 月期间在附属医院睡眠监测中心进行 PSG 检查的疑似 OSA 成年患者，共 225 例。数据采集和实验已获得医院伦理委员会的批准。实验过程中使用了符合标准的设备（PSG 设备：JE-912A，软件名称：polysmith11.0 版本，采样频率：500Hz）。如下图 2.2 所示。




图 2.2 PSG 设备

同时，对多个生理参数进行监测和记录，包括脑电图、眼电图、颏下肌电图、心电图、口鼻气流（采用鼻压力和热敏双传感器）、胸部和腹部应变计（用

于监测呼吸力运动)、胫前肌肌电图以及血氧饱和度(采用 Nonin 指夹传感器)和打鼾。本研究主要采用两种公认的记录打鼾信号的方法,一是将打鼾传感器一般放置在颈部气管旁记录打鼾信号,并严格按照美国睡眠医学会睡眠及相关事件评分手册^[14,15]设置打鼾参数(打鼾传感器的低频滤波器为 10Hz,高频滤波器为 100Hz,采样频率为 500Hz)。鼾声传感器(压电式鼾声传感器,型号 1250)是由 s.l.p.公司制造的。该传感器对皮肤接收到的睡眠呼吸声音和其他音频范围内的声音做出反应,并将它们转换成小的模拟电压,清晰可靠地指示这些声音的存在。压电式打鼾传感器具有较大的敏感区域以提高信号稳定性,并且具有柔软平坦的表面以密封环境噪声。第二、设置适当的高频滤波器(100Hz),睡眠呼吸声音可以在鼻压信号跟踪曲线中以快速振动波的形式出现,鼻压传感器检测到未经滤波的整晚的睡眠呼吸声音信号。原始录音共采集 225 名患者的睡眠呼吸声音信号音频信息,并配合一整夜的 PSG 测试来记录患者的 OSA 病情。睡眠呼吸声音录制普遍从晚上 22:00 到早上 08:00 左右,声音由鼾声传感器录制。睡眠呼吸声音信号的录制与 PSG 测试各自记录开始时间,并在之后的数据处理中进行对齐。患者检测示例如下图 2.3 所示。



图 2.3 PSG 检测患者示例

2.3.2 数据清洗

为提高采集到的睡眠呼吸声音信号的质量与可用性,确保符合实验所需的正确信号模式,需对数据进行清洗,处理因设备故障或其他原因所产生的错误

和不规范信号。过滤样本检查如下：

- (1) 睡眠呼吸声音信号打开遇到错误；
- (2) 睡眠呼吸声音信号与 PSG 的录制未同步；
- (3) 录制内容只包含设备底噪声的样本；
- (4) 信号采样率不同步（样本只选取采样率 500hz 的样本）；
- (5) 录制过程中，睡眠呼吸声音信号存在部分缺失；
- (6) 录制过程中，因患者清醒时间过多（失眠），未形成有效的睡眠呼吸声音。

上述不符合实验要求的样本对其进行留存处理（225 例患者都经过严格的 PSG 检测，虽然不符合睡眠呼吸声信号的处理，但数据都有效，保留到后续不需要用到睡眠呼吸声音信号的实验中进行多样本验证）。其中，在清洗数据时，存在第 2、5、6 类样本问题占大多数，可能的原因是患者在医院检测存在首夜效应，进而造成失眠现象，不易入睡。经过数据清洗这一过程，本文采集的睡眠呼吸声音信号可视为有效的数据集。

最终，本文筛选出 47 名患者用于提取 OSA 相关的睡眠呼吸声音信号。在这 47 名患者中，32 名为男性，15 名为女性。大多数患者年龄均超过 50 岁，并且以重度 OSA 患者为主，AHI 值大多在 30 以上。

参照美国睡眠医学会和 ICSD-3 指南的指导规则^[14,15]，由专家医生进行睡眠和相关事件的分析和判读。表 2.2 显示了 PSG 诊断中不同严重程度 OSA 患者的分布情况，其中重度 19 人，中度 15 人，轻度 7 人，正常 6 人。

表 2.2 患者严重程度分布

参数	正常	轻度OSA	中度OSA	重度OSA	汇总
AHI值 (/次)	AHI<5	5≤AHI<15	15≤AHI<30	AHI≥30	
数量 (/人)	6	7	15	19	47

2.3.3 数据切割

由于原始信号为患者一整晚的睡眠呼吸声音，时间较长且处理困难。将信号分割成等长且连续的片段有助于减少冗余信息、提高分析效率，并避免处理长时间信号时的复杂性和信息丢失。本文中每条信号的采样频率都为 500 Hz，

患者的睡眠声音数据被分割成大小时间长度相等的 2 分钟片段。分割过程如下图所示 2.4 所示。




图 2.4 信号分割过程

选择 2 分钟为滑动分割窗口时长，主要基于实验的需求和信号特征分析。2 分钟的时长能够充分涵盖睡眠过程中 AHE 的周期性变化，同时避免过长或过短的时间段带来数据处理的复杂性。较长的时间段可能会包含过多的冗余信息，而过短的时间段则可能导致信号特征不完整，因此 2 分钟的分割时长能够平衡数据的完整性和计算效率。

2.3.4 数据集构建

本文实验分为两个环节，旨在验证模型在不同临床条件下的适用性和可靠性。因此，将 47 例患者睡眠呼吸声音数据分为两批进行处理。

第一环节集中在模型的训练、测试和验证。研究从 47 例患者中随机选取 36 位，确保涵盖不同严重程度的 OSA 患者分布均匀，并对这些患者的信号数据通过 2.3.3 小节的切割方法获得 11850 个睡眠声音片段，其中包括 4852 个 AHE 事件片段和 6998 个正常睡眠片段。该环节的目的在于得出一个模型，帮助其准确识别和分割信号中 AHE 发生的时间区域。

第二个环节使用的是剩余的 11 例患者数据，这一阶段的目标是将第一阶段得到的模型应用于 OSA 的诊断和分级。为了提高模型的泛化能力和临床实用性，第二阶段的数据选取了新的患者群体，以更好地反映临床诊断的多样性和真实性。在这一环节中，每位患者的整晚睡眠呼吸声音信号将独立进行分割（分割方法见 2.3.3 小节），每组数据对应一位患者的完整睡眠信号，以便后续的 OSA 诊断和严重程度评估。

2.4 睡眠呼吸声音的滤波降噪

2.4.1 问题描述

处于医院复杂环境下采集到的原始声音信号，并不能直接用于 OSA 的识别和诊断，因为这些信号容易受到诸多干扰因素的影响，例如噪声（如运动伪影和工频噪声）可能与信号的频谱重叠，导致频谱混叠。信号通常在低频段有关键成分（例如 AHE），而噪声频谱往往跨越更宽的频带。滤波器需要在保留这些低频成分的同时，去除噪声成分。信号和噪声在频率域的表达见式（2.1）所示：

$$X(f) = S(f) + N(f), \quad (2.1)$$

其中， $S(f)$ 为信号频谱， $N(f)$ 为噪声频谱，滤波器应避免丢失关键信号频率。

个体差异（如年龄）会影响信号的频率和幅度，引起频谱变化，如式（2.2）所示：

$$S_{age}(f) = f * \alpha_{age}, \quad (2.2)$$

其中， α_{age} 是与年龄相关的频谱调整因子。滤波器设计需要考虑这些差异，避免过度平滑。

滤波器的带宽须有效去除噪声频段，同时保留关键信号成分。滤波器的传递函数的表达见式（2.3）所示：

$$H(f) = \begin{cases} 1, & \text{if } f \in [f_{\min}, f_{\max}] \\ 0, & \text{elsewhere} \end{cases}, \quad (2.3)$$

其中， $[f_{\min}, f_{\max}]$ 为信号的有效频带。

因此，从信号流中有效区分睡眠呼吸声音信号与噪声是信号处理中的关键。如果能够排除噪声干扰，确保最终提取到的是纯净的睡眠呼吸声音信号，将直接影响 OSA 诊断的准确性。而在实际应用中，信号滤波面临诸多挑战，例如频谱重叠、个体差异、滤波带宽选择和滤波器特性的优化等因素。这些问题的存在使得难以保证处理后的信号完全只包含目标信号。仅依靠人工去噪标注往往效果粗糙，难以达到理想效果。因此，需要通过精确选择和设计滤波降噪算法，

有针对性地去掉噪声，同时保留关键的睡眠呼吸声音成分，避免信号失真，这样才能确保信号达到理想的实验效果。下图 2.5 给出了一段 2 分钟左右的患者原始睡眠呼吸声音信号示例（红色框中的为有效睡眠呼吸声音信号特征，未框中的为非有效信号特征，即待去除的噪音）。




图 2.5 原始睡眠呼吸声音信号

2.4.2 数据格式转换

在信号滤波降噪过程中，原始信号数据需进行格式转换，以满足实验需求，确保数据适用于分析。具体而言，将原始数据转化为适合处理和分析的结构，并将其映射为坐标进行存储。转换后数据如图 2.6（b）所示。通过这种方式，数据的空间分布或其他特征可以直观呈现，便于后续的分析 and 可视化操作，进而为模型的训练和结果的解读提供支持。这一转换过程涉及对数据的归一化和标准化，确保实验中的数据在计算上能够准确无误地处理，并满足模型的输入要求。




图 2.6 信号格式转换

2.4.3 常用滤波降噪算法实现

降噪算法的目标是从噪声污染的信号中去除或减小噪声成分，使得信号更加清晰，容易被理解。它主要通过抑制背景噪声来增强信号质量。以下将采用谱减法、维纳（Wiener）滤波和卡尔曼滤波这三种常用的滤波降噪算法对信号进行分析，并对比本文患者原始信号数据处理前后的效果。

（1）谱减法

谱减法是一种基于频域的降噪方法^[62]。它假设噪声是平稳的，且在每个时刻噪声的频谱与语音的频谱是可分离的。该算法通过估计噪声频谱，并从带噪声的信号中减去噪声频谱，达到降噪的目的。实验采用该方法对原始睡眠呼吸声音信号进行处理。下图 2.7 为信号处理前后的对比（蓝色信号为原始信号，橙色为经过实验方法处理后的信号）。




图 2.7 信号经过谱减法前后对比

谱减法的具体实现过程为假设带噪声的信号为 $x(t)$ ，噪声为 $n(t)$ ，语音信号为 $s(t)$ ，那么：

$$x(t) = s(t) + n(t), \quad (2.4)$$

信号的频谱表示为 $X(f) = S(f) + N(f)$ ，其中 $S(f)$ 和 $N(f)$ 分别是语音信号和噪声信号的频谱。谱减法的基本思想是估计噪声频谱 $\hat{N}(f)$ ，减去噪声频谱得到干净的语音信号频谱 $\hat{S}(f)$ ：

$$\hat{S}(f) = \max(|X(f)|^2 - |\hat{N}(f)|^2, 0), \quad (2.5)$$

最后再通过逆短时傅里叶变换得到降噪后的信号。

(2) 维纳滤波

维纳滤波^[63]是一种通过最小均方误差估计，基于信号和噪声的功率谱估计来减少噪声的滤波方法。实验采用该方法对原始睡眠呼吸声音信号进行处理。下图 2.8 为信号处理前后的对比（蓝色信号为原始信号，橙色为经过实验方法处理后的信号）。




图 2.8 信号经过维纳滤波前后对比

维纳滤波的频域滤波器 $H(f)$ 由式 (2.6) 给出：

$$H(f) = \frac{P_s(f)}{P_s(f) + P_n(f)}, \quad (2.6)$$

其中， $P_s(f)$ 为信号的功率谱， $P_n(f)$ 为噪声的功率谱。

应用维纳滤波后，估计的语音信号为：

$$\hat{S}(f) = H(f) \cdot X(f), \quad (2.7)$$

最后，通过逆傅里叶变换得到降噪后的信号。

(3) 卡尔曼滤波

卡尔曼滤波是一种递归滤波方法，通过最小化均方误差，基于状态转移和观测方程进行信号的最优估计。具体更新的实现过程如下。

状态预测：

$$\hat{X}_k^- = A\hat{X}_{k-1} + Bu_k. \quad (2.8)$$

协方差预测：

$$P_k^- = AP_{k-1}A^T + Q. \quad (2.9)$$

卡尔曼增益：

$$K_k = P_k^- H^T (HP_k^- H^T + R)^{-1}. \quad (2.10)$$

状态更新：

$$\hat{X}_k = \hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-). \quad (2.11)$$

协方差更新：

$$P_k = (I - K_k H)P_k^-, \quad (2.12)$$

其中， $\hat{X}_k$ 是对系统状态的估计， P_k 是状态的协方差， A 和 H 是系统和观测矩阵， Q 和 R 是噪声协方差， K_k 是卡尔曼增益， Z_k 是观测值。实验采用该方法对原始睡眠呼吸声音信号进行处理。下图 2.9 为信号处理前后的对比（蓝色信号为原始信号，橙色为经过实验方法处理后的信号）。




图 2.9 信号经过卡尔曼滤波滤波前后对比

从上述的几种滤波降噪算法对原始数据处理的前后对比可知，处于复杂噪声背景下的睡眠呼吸声音信号，采用谱减法和卡尔曼滤波的效果不是很好，噪声并未得到有效抑制，而采用维纳滤波对数据进行降噪的效果比另外两种更有效，但还是有部分噪声存在。因此，常规的滤波降噪算法显然无法满足本次实际需求，易出现误判和丢失信号关键特征现象。最终，本文确定了一种基于多重技术融合的信号平滑去噪算法，算法结合了数据预加重、分帧加窗、小波变换和非线性变换相关技术，以此对睡眠呼吸声音信号进行去噪，取得了良好的效果。

2.4.4 基于多技术融合的滤波降噪算法实现

根据睡眠呼吸声音信号的特点，本文设计的平滑去噪算法结合了数据预加

重、加窗分帧、小波变换和非线性变换相关技术对原始睡眠呼吸声音信号进行平滑去噪处理。采用技术和实现具体步骤如下。

(1) 信号数据预加重

预加重通过一阶 FIR 高通数字滤波器去除口唇辐射的负面影响并提高睡眠呼吸声音信号的高频分辨率，增强信号的清晰度和质量，为后续的分析提供更精确的基础，其传递函数为^[64]：

$$H(z) = 1 - uz^{-1}, \quad (2.13)$$

其中 u 的取值范围为 0.9~1 之间，这里 u 的取值根据睡眠声音信号特点以及多次实验最终取 0.98。

设 n 时刻的睡眠呼吸声音采样值为 $x(n)$ ，经过预加重处理后的结果如式 2.14 所示：

$$y(n) = x(n) - ux(n-1). \quad (2.14)$$

(2) 信号数据分帧加窗

由于发声器官的惯性，语音信号在短时间内特征变化小，可视为稳态信号^[65]，因此在短时分析中将其分为 10-30ms 的一帧进行处理^[66]。而睡眠呼吸声音信号也可采用相同方法分析。

实验采用了交叠分段方法，通过重叠分帧保证原始信号的连续性。同时根据睡眠声音信号的特点及多次实验结果，帧移设置为帧长度的 40%，以确保不遗漏有价值的信息。如下图 2.10 所示。




图 2.10 帧移长度

睡眠呼吸声音信号采样后为 $x(n)$ ，通过分帧处理与有限长窗函数 $w(a)$ 相乘，

$$y_a(n) = x(n)w(a-n). \quad (2.15)$$

窗函数通常具有低通特性，不同的窗函数选择会影响带宽和频谱泄漏。常见的窗函数包括矩形窗、汉宁窗、汉明窗和布莱克曼窗。其具体公式定义如下：
矩形窗：

$$w(a) = \begin{cases} 1, & \text{if } a \in [0, N-1] \\ 0, & \text{otherwise} \end{cases} \quad (2.16)$$

汉宁窗：

$$w(a) = \begin{cases} 0.5(1 - \cos(\frac{2\pi a}{N-1})), & \text{if } a \in [0, N-1] \\ 0, & \text{otherwise} \end{cases} \quad (2.17)$$

汉明窗：

$$w(a) = \begin{cases} 0.54 - 0.46 \cos(\frac{2\pi a}{N-1}), & \text{if } a \in [0, N-1] \\ 0, & \text{otherwise} \end{cases} \quad (2.18)$$

布莱克曼窗：

$$w(a) = \begin{cases} 0.42 - 0.5 \cos(\frac{2\pi a}{N-1}) + 0.08 \cos(\frac{4\pi a}{N-1}), & \text{if } a \in [0, N-1] \\ 0, & \text{otherwise} \end{cases} \quad (2.19)$$

不同窗函数的选择会影响主瓣宽度和旁瓣衰减特性。表 2.3 列出了四种窗函数的对比。

表 2.3 四种窗函数对比

窗类型	主瓣宽度 (π)	第一旁瓣衰减 (dB)
矩形窗	2	13
汉宁窗	4	31
汉明窗	4	42
布莱克曼窗	6	58

根据表 2.3 的对比结果，本实验选择了汉明窗作为信号加窗函数，以有效减少信号处理中可能出现的频谱泄漏现象。汉明窗是一种常见的平滑窗函数，能够在频域中对睡眠呼吸声音信号进行加权，从而提高频谱估计的精度，尤其适用于抑制旁瓣泄漏的情况。

(3) 结合小波变换与非线性变换滤波降噪算法实现

根据信号特点，经过多次实验验证，最终设计了如下的去噪算法流程。

首先，进行高通数字滤波预加重，主要目的是去除睡眠呼吸信号中的低频成分，例如基线漂移。这些低频噪声会掩盖呼吸信号的高频变化，通过高通滤波，可以更好地突出信号的快速变化，帮助提取关键特征。此处理过程详见 2.4.4

(1) 小节。在此基础上，对信号进行非线性变换处理，通过增强信号中的振幅部分，尤其是在 AHE 发生时的前后呼吸声音状态，使得信号对这些显著变化变得更加敏感。这一操作能够显著提升对异常 AHE 的检测识别能力。计算见下式 2.20 所示：

$$y(t) = \begin{cases} x^2(t), & x(t) \geq 0 \\ -(x^2(t)), & x(t) < 0 \end{cases} \quad (2.20)$$

其次，应用小波变换进行处理。这是因为睡眠呼吸信号中常常伴随有多种频率的噪声（例如电噪声和运动伪影）。通过小波变换对输入信号进行分解和去噪，使用软阈值处理去除噪声成分，最后重构出去噪后的信号。小波变换的优势在于它能够在时频域之间灵活切换，适用于处理具有多尺度特征的睡眠呼吸信号，有效去噪并保留数据的主要结构和特征。小波分解公式如下式 2.21 所示：

$$X(t) = \sum_{k=1}^L (A_k(t) + D_k(t)), \quad (2.21)$$

其中， $A_k(t)$ 表示低频部分，即信号的主要部分。 $D_k(t)$ 表示高频部分，即信号的细节成分。 L 是分解的层数，决定了信号被分解成多少层。

在去噪过程中，需要设置一个阈值，通常通过细节系数来估算信号的噪声幅度。在本次处理过程中，阈值 T 是通过最后一层小波细节系数的绝对值均值除以 2 来设置的，其表达见式 2.22 所示：

$$T = \frac{1}{N} \sum_{i=1}^N |D_L(i) / 2|, \quad (2.22)$$

其中， $D_L(i)$ 是第 L 层小波细节系数的第 i 个分量， N 是系数的数量， T 为计算得到的阈值。

软阈值是通过将系数的幅度缩小到阈值以下的部分设为 0，剩余部分则按阈

值平移，其表达见式 2.23 所示：

$$\hat{C}(i) = \begin{cases} C(i) - T, & C(i) > T \\ C(i) + T, & C(i) < -T, \\ 0, & |C(i)| \leq T \end{cases} \quad (2.23)$$

其中， $C(i)$ 是某一层的小波系数， $\hat{C}(i)$ 是阈值处理后的系数。

去噪后，将处理过的小波系数进行重构，得到去噪后的信号。小波重构使用小波逆变换。其表达见式 2.24 所示：

$$\hat{X}(t) = \sum_{k=1}^L (A_k(t) + \hat{D}_k(t)), \quad (2.24)$$

其中， $\hat{D}_k(t)$ 是经过阈值处理后的高频部分，即细节系数。

在实际的信号处理中，重构后的信号可能会由于去噪和平滑等处理步骤的影响，导致信号与原始信号的长度略有不同。因此，通过以下公式 2.25 将信号裁剪为原始长度：

$$\hat{X}(t) \leftarrow \hat{X}(t)[1:N], \quad (2.25)$$

其中， N 是原始信号的长度。

最后，汉明窗平滑去除信号中的快速波动和随机噪声，运算过程详见 2.4.4 (2) 小节。通过平滑处理，信号的稳定性能得到显著增强，为呼吸模式的识别和异常事件的检测提供了更加清晰和可靠的依据。

经过上述这些方法的处理和实现，原始信号中的噪声得到有效抑制，同时关键特征得到了显著增强。这些处理步骤通过去除不必要的干扰，保留了信号的本质特征，为后续的呼吸模式识别和呼吸异常检测提供了更加稳定、清晰的信号基础。通过这些优化，方法能够更准确地捕捉到声音信号中的微小变化，进而实现更精确的分析和检测。

最终算法的去噪效果如下图 2.11 所示（蓝色为原始信号，橙色为处理后的信号）。从图中可以看出，本文所设计的滤波降噪算法能够有效的去除睡眠呼吸声音外的干扰，达到实验预期。




图 2.11 患者睡眠呼吸声音去噪检测对比

2.5 本章小结

本章主要探讨了睡眠呼吸声音与 OSA 病理关系，PSG 设备在 OSA 诊断中的应用以及 AHI 指数对病情的量化。同时，介绍了睡眠呼吸声音信号的原始数据预处理过程，包括数据集构建和滤波降噪方法的详细描述，并分析了信号在传统滤波降噪算法中的应用效果。最终，设计了一种基于多技术融合的信号滤波降噪算法，并对医院返回的患者睡眠呼吸声音信号进行了实验验证。结果表明，本文提出的算法在复杂噪音环境下优于传统滤波降噪算法，具有较高的去噪准确率和良好的鲁棒性。本章对原始信号的处理至关重要，准确获取目标睡眠呼吸声音段为后续信号分割和 OSA 病症识别奠定了基础。

第3章 睡眠呼吸声音信号分割

医学图像在疾病诊断和治疗规划中越来越重要，本章的研究也主要集中在医学图像分割领域。由于个体差异，整夜睡眠呼吸声音信号采样后形成的不规则图像（见第二章图 2.5），传统方法难以准确分割。本章基于第二章所构建的数据集及经过预处理后的信号数据，进行分析、设计和搭建了一种 FM-DS-U-Net 信号分割网络，并进行了训练、测试和验证。该网络旨在实现对睡眠呼吸声音信号中 AHE 发生区域的精准识别和分割，为后续 OSA 严重程度评估提供有力支持。本章内容具体安排如图 3.1 所示。




图 3.1 内容安排

3.1 基于 FM-DS-U-Net 的分割网络

3.1.1 问题描述与设计思路

在深度学习的分割任务中，卷积操作通常伴随着下采样，这虽然能够扩大感受野，但也会导致信息丢失。与此同时，上采样过程中常常会遇到信息恢复不足的问题，影响了分割精度。本文的对象是睡眠呼吸声音信号，需要对信号采样点归属和 AHE 的起止点判断较为精确，如果出现较大偏差，就会导致分割结果不够精确，从而影响最终的 OSA 诊断。这些问题的根本原因在于信息的丢

失与不足，以及模型对精细特征的捕捉能力不足。为了解决这些问题，本章结合控制论中反馈思想，引入反馈路径机制，以实现信息复用和多尺度信息融合，同时结合注意力机制和深度可分离残差结构来提高分割精度，从而提升整体性能。

本章对睡眠呼吸声音信号进行分割，设计了一种 FM-DS-U-Net 分割网络，该网络基于 U-net3+ 架构，融合反馈机制、CBAM 机制和深度可分离残差，精确划分每个采样点是否为 AHE 发生点归属，从而准确地定位出 AHE 发生的时间范围，实现信号的精准分割。其中，反馈机制通过修正网络输出，增强网络对复杂背景和模糊边界的鲁棒性，使其能根据先前的学习经验调整分割结果；解码器采用深度可分离残差结构，并结合 CBAM 注意力机制，帮助 U-Net3+ 自动聚焦关键区域，避免干扰。这种结合不仅增强了模型的自适应能力，使其在不同区域特征分布变化的情况下能够自我优化，提高了分割精度，而且提升了模型的稳定性和泛化能力，确保其对不同输入的响应更加稳定，从而避免了特征丢失，进一步提高了分割效果。

3.1.2 技术分析

(1) U-net3+网络

U-Net^[67]网络具有独特的 U 型结构能够有效融合深层和浅层特征，提升图像分割效果。同时，为了克服 U-Net 在全尺度信息获取上的不足，本研究采用改进后的 U-Net3+^[68]网络，通过结合不同尺度的特征信息并使用深度监督优化边界分割能力。U-Net 与 U-Net3+ 网络架构对比如下图 3.2 所示。




图 3.2 U-Net 与 U-Net3+ 网络架构

U-Net3+通过全尺度跳跃连接，允许解码器接收来自编码器的多尺度特征，从而在全尺度上有效捕获细粒度细节和粗粒度语义。特征图 X_{De}^i 计算方法见式 (3.1)：

$$X_{De}^i = \begin{cases} X_{En}^i, & i = N \\ Y \left(\left[\underbrace{C(D(X_{En}^k))_{k=1}^{i-1}}_{Scales: 1^{th} \sim i^{th}}, \underbrace{C(X_{En}^i)}_{Scales: i^{th}}, \underbrace{C(U(X_{De}^k))_{k=i+1}^N}_{Scales: (i+1)^{th} \sim N^{th}} \right] \right), & i = 1, \dots, N-1 \end{cases} \quad (3.1)$$

其中， C 为卷积操作， Y 为特征聚合机制， D 和 U 分别为上采样和下采样操作， i 为第 i 个下采样， N 为编码器个数。

以 X_{De}^3 为例，通过最大池化和卷积调整编码器特征，解码器通过上采样和卷积调整大尺度特征，最终拼接并聚合得到 X_{De}^3 特征图。全尺度跳跃连接如下图 3.3 所示。




图 3.3 全尺度跳跃连接

此外，U-Net3+通过引入分类导向模块提升分割精度，特别是解决边界模糊问题。该模块预测目标区域的存在概率，使用交叉熵损失训练并通过 Argmax 输出[0,1]值，最终与解码器分割结果相乘，进而提高精度。分类导向模块如下图 3.4 所示。




图 3.4 分类导向模块

(2) CBAM 机制

CBAM（Convolutional Block Attention Module）^[69]由通道注意力和空间注意力机制两部分构成，通过评估通道重要性和突出关键区域，增强特征表示，具有即插即用的轻量级结构。与其他机制相比，如 DANet(Dual Attention Network)，CBAM 凭借其简洁高效的设计和较低的计算开销，已经能够充分满足实验需求，并在保证性能的同时，显著减轻计算负担。CBAM 结构如下图 3.5 所示。




图 3.5 CBAM 结构示意图

在通道注意力阶段，输入特征 F 通过全局平均池化和全局最大池化生成通道描述符，然后通过共享多层感知机（Shared MLP）和 Sigmoid 激活函数生成特

征 M_c ，最后与输入特征 F 逐通道相乘得到输出特征 F' 。计算方法如式 (3.2) 所示：

$$M_c(F) = \text{Sig}(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F))). \quad (3.2)$$

空间注意力阶段， F' 经过池化、拼接、 7×7 卷积和 Sigmoid 激活得到空间注意力特征 M_s ，与原始特征相乘。计算方式如式 (3.3) 所示：

$$M_s(F) = \text{Sig}(f^{7 \times 7}([\text{AvgPool}(F); \text{MaxPool}(F)])). \quad (3.3)$$

式(3.2)和(3.3)中： AvgPool 表示平均池化； Sig 表示 Sigmoid 函数； MaxPool 则表示最大池化。CBAM 通过结合通道注意力和空间注意力机制，分别优化特征图的通道和空间信息，从而提升模型的性能。

(3) 深度可分离卷积

深度可分离卷积^[70]将标准卷积分解为深度卷积和逐点卷积，通过先过滤再组合的方式显著减少计算量和模型大小，提升计算效率。图 3.6 展示了这一分解过程的原理。




图 3.6 深度可分离卷积原理

标准卷积的参数数量如式 (3.4) 所示：

$$P_A = D_k^2 \times M \times N, \quad (3.4)$$

标准卷积层由大小为 $D_k \times D_k \times M \times N$ 的卷积核 K 来参数化，其中 D_k 为假设的平

方核的空间维度， M 为输入通道数， N 为定义的输出通道数。

深度卷积的参数数量如式 (3.5) 所示：

$$P_B = D_k^2 \times M. \quad (3.5)$$

深度可分离卷积的参数数量如式 (3.6) 所示：

$$P_C = D_k^2 \times M + M \times N. \quad (3.6)$$

深度可分离卷积参数数量对比标准卷积参数数量如式 (3.7) 所示：

$$\frac{P_C}{P_A} = \frac{D_k^2 \times M + M \times N}{D_k^2 \times M \times N} = \frac{1}{N} + \frac{1}{D_k^2}. \quad (3.7)$$

由式 (3.7) 可见，深度可分离卷积显著提高了计算效率。

(4) 残差网络

残差网络 (Residual Network, ResNet) [71] 通过引入恒等映射和快捷连接优化残差函数 $F(X)$ ，从而简化特征学习并提高模型相关性能。图 3.7 展示了残差结构。




图 3.7 残差结构

3.1.3 FM-DS-U-Net 网络设计实现

FM-DS-U-Net 网络保留了 U-Net3+ 的全尺度跳跃连接, 通过多尺度特征融合, 有效地捕获细粒度与粗粒度的语义信息。在此基础上, 网络在编码器端和解码器端均引入了反馈机制, 以进一步提升特征提取的能力。具体而言, 反馈机制通过在编码器和解码器各层之间增加反馈路径, 确保每一层的特征图在传递过程中得到更新。编码器端的反馈节点通过下采样操作将上一层的特征信息传递到当前层, 这使得当前层的特征图能够得到更充分的上下文信息, 从而增强其特征表达能力。在解码器端, 反馈节点通过上采样操作将来自后续层的特征信息返回到当前层, 帮助当前层更好地恢复高分辨率的细节信息, 增强分割精度。这样的反馈机制有效地解决了信息流失的问题, 并促进了不同层级特征的有效融合。此外, 深度可分离残差结构替代了解码器中的普通卷积模块, 减少了模型的参数量和计算复杂度, 同时提高了特征提取和融合的效率。结合 CBAM 机制, FM-DS-U-Net 能够更加精准地聚焦于睡眠呼吸声音信号的关键特征, 从而显著提升分割精度。FM-DS-U-Net 网络结构设计如图 3.8 所示。




图 3.8 FM-DS-U-Net 网络结构示意图

编码器通过将传统卷积操作替代为深度可分离卷积, 并引入残差结构, 构建了高效的深度可分离残差块。卷积部分采用 3×3 卷积核, 初始通道数为 32, 实验效果最佳。随着网络加深, 常规卷积会带来较大计算负担, 尤其在处理睡眠呼吸声音信号时, 模型需要快速输出以帮助医生及时判断。因此, 为提高计算效率, 引入了深度可分离卷积。同时, 在每个模块后, 都加入 CBAM 机制, 通

过通道和空间注意力优化输出。此外，深度可分离残差结构通过替换传统卷积并引入批归一化层，进一步提高了网络效率。编码器设计部分结构如图 3.9 所示。其中，ReLU 为激活函数，BN 为批量归一化层。




图 3.9 编码器部分结构示意图

解码器则接收来自不同尺度的编码器、中间层及上级解码器输出特征，进行拼接后送入特征融合模块处理，经过两轮处理后进行上采样。其结构如图 3.10 所示。




图 3.10 解码器部分结构示意图

3.2 实验与分析

3.2.1 实验环境

具体的实验环境配置如表 3.1 所示。

表 3.1 实验环境

硬件配置信息	参数
操作系统	Windows
GPU	NVIDIA GeForce RTX 3090
Pytorch	版本：2.0.1
Python	版本：3.9.17

3.2.2 实验设计与数据集准备

本次研究中的实验数据采集于 2020 年 9 月至 2024 年 10 月期间在附属医院睡眠监测中心进行 PSG 检查的疑似 OSA 成年患者,共 36 例。患者的各项指标如下表 3.2 所示：

表 3.2 患者详细生理信息

指标	平均值	最大值	最小值
年龄（岁）	60	81	24
身高（cm）	164	182	150
体重（kg）	67.3	103	47.5
BMI指数（kg/m ² ）	24.4	31.2	17.51
整夜AHE个数（次）	216	753	13
AHI（次/小时）	36.6	87	0
单次AHE时长（秒）	21.6	67.6	10.3
整夜记录睡眠时间（h）	8.72	9.46	7.92

每位患者的睡眠呼吸声音信号均严格参照相关手册规则^[14,15]关于呼吸紊乱

事件的判读标准，通过脑电和眼电生理电判断微觉醒状态，比对指压、鼻压和耳压判断气流曲线，并在附属医院专家医生协助下进行标注，详细标出了 AHE 的发生时间区域。如图 3.11 为根据专家医生的注释绘制的某一段重度 OSA 患者的睡眠呼吸声音信号示例。




图 3.11 专家医生注释可视化

上图中，按照相关专家医生注释的 AHE 起止点，实验用不同颜色区分了不同的信号波形，其中橙色为 AHE 发生持续时长，蓝色为正常睡眠呼吸声音信号。同时，为了方便后续的模式训练和分析，采用 one-hot 编码将信号波形数字化，其中数字 0 表示无关波形，数字 1 表示 AHE 发生波形，设置方式如图中绿色线条所示。

将制作好的睡眠呼吸声音信号数据划分为训练集、测试集和验证集，比例为 6.4:1.6:2。同时，为了增强训练集的多样性和提高模型的鲁棒性，本文对训练集中的少数类别（如 AHE 的片段）进行了数据增强。数据增强的策略包括对原始信号进行时域和频域上的各种处理，如时间伸缩和音量变化等，从而平衡不同类别之间的数据分布，避免类别不平衡对模型训练造成的不利影响。增强后的数据集可平衡各类数据比例，有助于提升模型的泛化能力，确保其在实际应用中的准确性与稳定性。通过这种数据集的构建和增强策略，实验能够有效地训练出一个高效且准确的 AHE 检测分割模型，使最终模型具有较高的分割精度

和应用价值。

3.2.3 参数设置

训练过程中的超参数设置对实验结果至关重要。考虑到睡眠呼吸声音的特点、实验设备的限制以及训练速度的需求等。本实验选择了 Adam 优化器，该优化器能够在实验中展现出较好的鲁棒性和稳定性，帮助提高模型的性能。损失函数则选择了广泛应用的交叉熵损失函数。此外，批大小的设定为 8，以平衡内存占用和训练效率。最后，根据多次实验结果，学习率的设置为 0.0001 时，模型能够在合理的时间内稳定收敛，同时避免过大或过小的学习率带来的训练不稳定性或过慢的收敛速度。损失曲线如下图 3.12 所示。




图 3.12 损失曲线

3.2.4 评估指标

为了全面评估本章提出的诊断方法实验效果，本文使用敏感度（Se）、阳性预测值（PPV）和 F1 值作为衡量算法性能的指标。敏感度表示正确识别为正

例的比例，阳性预测值则反映了预测为正例且实际为正例的准确度，F1 值则为评估模型在查准率和查全率之间的平衡表现。 Se 、 PPV 和 $F1$ 的计算公式如下：

$$Se = \frac{TP}{TP + FN}, \quad (3.8)$$

$$PPV = \frac{TP}{TP + FP}, \quad (3.9)$$

$$F1 = 2 \times \frac{Se \times PPV}{Se + PPV}, \quad (3.10)$$

其中， TP 代表被正确识别为正例的特征波形， FP 代表被错误归类为正例的背景波形， FN 则代表被错误归类为负例的特征波形。

3.2.5 实验预测结果

根据实验训练确定最优模型，在验证数据上（区分四种不同严重程度 OSA）评估模型性能。表 3.3 为模型在验证集上对 AHE 检测所得到的各项指标。

表 3.3 模型检测结果

		F1 (%)	Se (%)	PPV (%)
正常 OSA 患者	AHE 起点	60.86	59.54	58.74
	AHE 终点	56.84	57.92	56.38
轻度 OSA 患者	AHE 起点	61.52	59.86	59.62
	AHE 终点	58.32	57.64	56.26
中度 OSA 患者	AHE 起点	83.56	82.16	80.24
	AHE 终点	80.43	83.23	79.42
重度 OSA 患者	AHE 起点	92.36	92.18	91.21
	AHE 终点	91.72	92.56	90.48

图 3.13 中给出了 AHE 的预测结果可视化（随机选取一段 120s 重度 OSA 患者的睡眠呼吸声音信号，上图黄色区域为医生标注的 AHE 发生时间区域，下图

黄色区域为模型预测 AHE 发生时间区域)，与医生标注结果进行对比可以看出，模型在重度 OSA 患者的预测上较为精确，几乎准确地预测了各个 AHE 的发生。而在程度较轻的患者声音信号上的预测有偏差（随机选取一段 120s 轻度 OSA 患者的睡眠呼吸声音信号），如图 3.14 所示，模型在事件预测中可能会误测出多余的部分区域。




图 3.13 切割示例图 1（重度 OSA 患者）




图 3.14 切割示例图 2（轻度 OSA 患者）

3.2.6 误差容忍度对实验结果的影响

实验过程中，误差指的是实验检测到的采样点与专家医生所标注的采样点差异，当差异小于容忍阈值时，视为检测准确。本次实验的患者睡眠呼吸声音为采样率 500Hz，上述实验结果以参照当前医疗器械协会研究的标准误差容忍度值 150 毫秒为界限，换算成采样率则是以 75 个采样点范围内为界限判定是否检测正确。然而，实验过程中对所采集的患者睡眠呼吸声音信号的波形图 and 对应时间点的呼吸起伏音调观察可知，睡眠呼吸声音信号的生成波容易受到睡眠过程中多种因素影响，可能由于患者的鼻音拖拽或呼吸声音音调起伏等会造成一定程度影响。因此在这里，本文从波形对比呼吸起伏音调的观测中适当调整误差容忍度的界限值在 150-400 毫秒范围为合理范围（150ms、200ms、250ms、300ms、350ms、400ms），进而观察实验结果。图 3.15、图 3.16、图 3.17 和图 3.18 为模型在四种不同严重程度 OSA 中采用不同误差容忍度下的结果对比。其中，横坐标表示不同的误差容忍度值大小，纵坐标表示对应各评估指标的实验结果准确率。




图 3.15 不同容忍度误差下正常人群对比




图 3.16 不同容忍度误差下轻度 OSA 人群对比




图 3.17 不同容忍度误差下中度 OSA 人群对比




图 3.18 不同容忍度误差下重度 OSA 人群对比

3.3 实验结果分析

经过多次实验,本文对患者整夜睡眠呼吸声音信号进行预处理后,再设计与之相适应的网络模型进行训练,最后使用模型对睡眠呼吸声音信号中的 AHE 进行识别和分割,效果显著。尤其在重度 OSA 患者的识别上,基本上符合专家医生标注效果(如图 3.13 所示)。但在 OSA 病症较轻的睡眠呼吸声音信号中仍存在一定误差(如图 3.14 所示),问题主要集中对于 AHE 前后呼吸声之间的误判和识别率需要加强。同时在 3.2.6 小节的误差容忍度实验结果可以看出,随着实验将误差容忍度值逐渐扩大,其各类评估指标的准确性也随之提高。然而,四种不同严重程度的 OSA 人群中,不同误差容忍度值对准确率的提升趋势有所不同。量化的 6 次实验中,重度 OSA 人群的提升幅度较缓慢(如图 3.18 所示),而正常或轻度 OSA 人群呈现较快的提升趋势(如图 3.15 和图 3.16 所示)。因此,针对不同严重程度的 OSA 人群,误差容忍度值的设定需要进一步的分析和确定。具体原因如下:

(1) 样本量不足

由于受限于实验条件和患者数量，总患者虽有 225 例经过 PSG 检测并得出诊断结果，但本研究仅收集到 47 例符合标准的睡眠呼吸声音信号数据。在后续的 OSA 严重程度评估中，模拟临床条件，故保留 11 例未经过处理的患者的数据用于单独评估。因此，模型训练、测试和验证所使用的样本数据最终保留了 36 例，样本量略显不足。

（2）误差容忍度设置

由于采集到的睡眠呼吸声音信号受到多种干扰因素的影响，如个体呼吸波形、音强和音调的波动不一致等。因此，实验中误差容忍度值的设定尚不明确，这不可避免地会导致一定的准确率偏差。然而，针对睡眠呼吸声音信号，要设置合适的误差容忍度值，仍需通过大量样本的观察和研究进行深入分析才能得出。

3.4 本章小结

本章根据所采集到的睡眠呼吸声音信号特点，主要设计了 FM-DS-U-Net 网络并在睡眠呼吸声信号特征波形分割中进行应用。实验过程中采用了来自附属医院所采集到的数据，验证得出，所训练的模型能够准确地检测睡眠呼吸声信号中发生 AHE 的起始点，尤其在重度 OSA 患者的数据上能实现信号的精确分割。实验结果表明，本文提出的方法在睡眠呼吸声音信号的分割任务中表现出色。最后，本文也对实验不足的地方进行了分析，以期在未来研究中可以进一步优化调整。本章的模型研究为后续工作提供了一个良好的目标模型，这对后续患者 OSA 病症严重程度判别分析的顺利开展十分重要。

第4章 AHE 参数的识别研究 and 应用

本章基于患者睡眠期间的呼吸声音信号数据，结合第三章所训练好的模型进行评估与预测，旨在检测信号中 AHE 的持续时间，并进一步提出一种基于患者整晚 AHE 持续时间占总睡眠时间的比值（参数 S ）来进行 OSA 诊断和分级的方法。在本章中，详细介绍了 AHE 持续时间的提取流程，以及实验参数 S 值的设计思路，并对实验结果进行了分析与比较，重点探讨了基于 PSG 诊断的参数 S 值与睡眠呼吸声音信号诊断的参数 S 值，以及传统判别标准 AHI 值之间的相关性。通过这些比较，能够评估基于睡眠呼吸声音信号的诊断方法在 OSA 识别和分类中的有效性，验证该方法与传统诊断标准之间的关系及潜在应用价值，最后对实验过程和结果进行了深入分析与讨论。

4.1 AHE 持续时间评估 OSA 严重程度

4.1.1 AHE 持续时间识别

在数据处理阶段，本文采用 One-Hot 编码的方式（参考图 3.11）将不同的睡眠呼吸声音信号波形数字化，从而为每种信号分配一个唯一的向量表示。具体来说，数字 0 表示正常睡眠呼吸声音波形，而数字 1 表示 AHE 的发生波形。当某一时刻发生 AHE 时，相应的标签被表示为二维向量 $(0, 1)$ ，其中 0 代表非 AHE 状态，1 代表 AHE 发生状态。这种标签形式使得计算机能够准确识别并区分睡眠呼吸声音信号中的 AHE。

在本次实验中，采用了 500Hz 的采样频率进行数据采集，意味着每秒钟采集 500 个数据点。因此，每个标签对应的事件持续时间为 0.002 秒。在模型识别过程中，通过 GPU 加速处理测试数据，最终输出每个时间点的 OSA 相关事件标签。为了提高准确度，在后处理阶段，本文对识别结果进行了进一步优化，主要通过过滤短时间误判事件来提升精度。具体而言，采用 AHE 的普遍判读标准^[54,72]：如果某一 AHE 的持续时间大于 70 秒小于 10 秒，则判定为误判，不视作真实的 AHE 发生，考虑到实验分割方式问题，观察实验数据分割状况，本次

实验设置的范围为 5-70 秒为合适范围。

此外，对于识别出的每个有效 AHE，本文统计并汇总标签为 1 的时长，并将其换算为实际时间进行详细记录。而未被判定为 AHE 的时间段则不做任何记录。这一处理过程有效地提升了 AHE 持续时间的识别精度，并确保结果的可靠性。

4.1.2 AHE 持续时间占比参数 S

目前，OSA 的严重程度评估通常依赖于 AHI 参数，但相关研究也表明，AHI 在许多方面存在局限性。有研究提到^[57,58]，患者夜间 AHE 的总持续时间与 OSA 的症状和严重程度之间具有相关性。尽管针对这一关系的研究尚不多，但本章的目的之一是通过分析患者整晚检测到的 AHE 持续时间与 OSA 严重程度之间的关系，验证是否可以通过 AHE 在整夜睡眠中总持续时间所占比例来评估 OSA 的严重程度，从而为 OSA 病情评估提供更为精确的参考标准。相关计算公式如下。

传统判读参数 *AHI*：每小时 AHE 次数的平均值，如式（4.1）所示：

$$AHI = \left[\frac{\text{整夜AHE发生次数（/次）}}{\text{整夜睡眠时长（/小时）}} \right]. \quad (4.1)$$

实验判读参数 *S*：AHE 总持续时间与总睡眠时间之比，如式（4.2）所示：

$$S = \left[\frac{\text{整夜AHE总持续时间（/秒）}}{\text{整夜睡眠时长（/秒）}} \right]. \quad (4.2)$$

该比值用于评估 AHE 持续时间占整晚睡眠时间的相对比例（公式中的 *S* 值为本文提出的比值计算，为开放式。后续研究人员还可以从其他生理信号中计算 *S* 值）。

具体计算方法：首先计算出整晚检测中出现的每次 AHE 持续时间，并将其累加。然后，将累积时间除以整个夜间睡眠监测的总时间，得到比例 *S* 值。通过累积 AHE 持续时间并与患者整晚睡眠时间进行比较，可以得到比较统一的评估标准，评估 AHE 持续时间占患者整晚睡眠时间的比例，进而采用比值大小去评估其严重程度。

4.2 实验与分析

4.2.1 实验设计与数据集准备

本章实验环境配置同 3.2.1 小节。

实验分为两阶段进行，因此数据被分为两批。第一阶段提取患者的整体 PSG 诊断报告，计算 PSG 检测得到的不同程度 OSA 患者整晚睡眠期间 AHE 持续时间占总睡眠时间的 S 值比例。目的是验证 AHE 总持续时间与 OSA 严重程度之间的关系，验证是否可以根据 S 值进行判断，从而为 OSA 的评估提供一种新的方法，同时为第二阶段实验开展的有效性提供支撑。在第二阶段，利用第三章所训练好的模型自动检测基于同一批患者整晚睡眠呼吸声音信号，检测信号中 AHE 的持续时间，并计算 S 值。最后将通过模型提取出的 S 值与经过 PSG 检测提取出的 S 值结果进行验证。

第一阶段实验选取了 2020 年 9 月至 2024 年 10 月期间在附属医院睡眠监测中心进行 PSG 检查的疑似 OSA 成年所有患者,共计 225 例。该阶段实验的主要目的是验证 AHE 的持续时间与诊断 OSA 严重程度之间的相关性。实验过程中，只需提取 PSG 检测结果中的 AHE 持续时间数据，并按照本次实验设计的 S 值计算方式进行分析。在此过程中，不需要用到睡眠呼吸声音信号。因此，所有接受过正规 PSG 检测的患者，无论是否符合标准睡眠呼吸声音数据要求，均可纳入实验数据进行验证分析。这一实验设计能够充分利用现有的 PSG 数据，确保实验结果的广泛适用性和有效性。

表 4.1 显示了 PSG 诊断中不同严重程度 OSA 患者的分布情况，其中重度患者 51 人，中度患者 37 人，轻度患者 47 人，正常患者 90 人。表 4.2 显示了患者的详细指标信息。

表 4.1 不同程度 OSA 患者分布

参数	正常	轻度OSA	中度OSA	重度OSA	汇总
AHI值 (/次)	AHI<5	5≤AHI<15	15≤AHI<30	AHI≥30	
数量 (/人)	90	47	37	51	225

表 4.2 患者详细生理信息

指标	平均值	最大值	最小值
年龄（岁）	58	85	21
身高（cm）	166	185	149
体重（kg）	65.1	103	45.5
BMI指数（kg/m ² ）	24.6	31.5	17.47
整夜AHE个数（次）	202	753	7
AHI（次/小时）	29.6	87	0
单次AHE时长（秒）	19.7	67.6	10.1
整夜记录睡眠时间（h）	8.32	9.46	7.22

第二阶段的实验采用了睡眠呼吸声音信号。首先，从 225 例患者中筛选出符合标准的 47 例患者进行信号数据处理（筛选过程详见 2.3.2 小节）。为了符合临床和模型训练验证的相关要求，47 例患者信号数据被分为两组：37 例用于模型的训练及验证，剩余的 11 例用于评估训练好的模型在 OSA 严重程度诊断中的准确性。在这 11 位患者中，每位患者的整晚睡眠呼吸声音信号都会进行单独分类切割，并以每人次为单位进行 OSA 的评估诊断。为确保信号质量，信号都经过滤波降噪处理后，再按照本次实验设计方法，使用训练好的模型检测信号中 AHE 发生的总持续时间，进一步计算每位患者的 S 值，并通过 S 值评估 OSA 的严重程度。最终，将诊断结果与 PSG 检测结果进行对比分析，以得出相应结论。

表 4.3 显示了 11 例患者经过传统 PSG 检测和诊断的结果信息，为保护患者信息，名字以编号代替。

表 4.3 患者信息

患者编号	性别	年龄	BMI	AHI	诊断结果
01	女	66	21.00	3.19	正常
02	男	62	17.65	2.82	正常
03	男	52	25.35	13.52	轻度
04	女	47	23.53	14.97	轻度

续表 4.3 患者信息

患者编号	性别	年龄	BMI	AHI	诊断结果
05	男	61	20.96	21.45	中度
06	男	65	24.80	29.33	中度
07	男	52	25.00	23.56	中度
08	女	64	24.44	41.72	重度
09	男	74	24.38	49.77	重度
10	男	35	28.89	64.49	重度
11	男	56	26.30	54.64	重度

4.2.2 S 值参数的有效性对比

提取经 PSG 检测获得的 225 名患者的 PSG 报告数据,分析和计算出每位患者报告中检测到的 AHE 总持续时间,并以 4.1.2 小节实验所设计方法得出各患者的比例 S 值。表 4.4 为传统 AHI 值与实验 S 值的对比,用于确定 OSA 的严重程度范围。表 4.5 显示了 225 例患者经由 PSG 诊断出的 S 值对比 AHI 值诊断的准确性。图 4.1 为 PSG 诊断 S 值结果测定是否患有 OSA 症状(紫色虚线为是否患有 OSA 病症分界线,详见表 4.5)。图 4.2 为 PSG 诊断 S 值结果测定 OSA 四种严重程度的 S 值分布(紫色虚线为 OSA 不同严重程度分界线,详见表 4.5)。

表 4.4 传统 AHI 值与 S 值确定 OSA 的严重程度范围对比

参数	正常	轻度OSA	中度OSA	重度OSA
AHI值(次)	$AHI < 5$	$5 \leq AHI < 15$	$15 \leq AHI < 30$	$AHI \geq 30$
S值(百分比)	$S < 0.023$	$0.023 \leq S < 0.080$	$0.080 \leq S < 0.178$	$S \geq 0.178$

表 4.4 中为 AHI 与 S 值判读情况对比。因样本量有限,表中 S 值为参照本次实验 225 例患者结果所设定。0.023:正常人群中最大 S 值或轻度 OSA 中最小 S 值; 0.080:轻度 OSA 中最大 S 值或中度 OSA 中最小 S 值; 0.178:中度人群最大 S 值或重度 OSA 中最小 S 值。

表 4.5 传统 AHI 值与 PSG-S 值诊断准确性对比

参数	正常	轻度OSA	中度OSA	重度OSA	汇总
AHI值诊断 (/人)	90	47	37	51	225
S值对比AHI值诊断相同 (/人)	89	43	33	49	214
S值对比AHI值诊断严重程度	98.89%	91.49%	89.19%	96.09%	95.11%
S值对比AHI值诊断患有OSA	98.89%	100%	100%	100%	99.56%

表 4.5 中显示了对 225 例患者进行 PSG 诊断，按照 AHI 参数值分类严重程度，随后进行实验参数 S 值的判定，并比较了 S 值判定结果与 AHI 值分类的准确性。




图 4.1 PSG 诊断为 OSA 症状人群的 S 值分布




图 4.2 PSG 诊断 OSA 严重程度的 S 值分布

由上述表 4.5、图 4.1 和图 4.2 所示的 PSG 诊断的整夜 AHE 总持续时间与整夜睡眠时间之比显示的结果中可以看出，四种 OSA 程度患者的最终比例分布较为均匀，与 AHI 指数诊断严重程度相比，OSA 症状的正确诊断率可达 99.56%，OSA 严重程度的判断准确率平均可达 95.11%。这表明，用患者在整个睡眠过程中检测到的 AHE 总持续时间所占的 S 值来评价患者是否存在 OSA 及其严重程度具有可行性。这一发现提供了一种新的量化指标用于评估 OSA，为后续更全面的诊断和治疗决策提供有价值的参考。

4.2.3 S 值的应用测试

由 4.2.2 小节的实验结论可知，AHE 的持续时间是可以诊断 OSA 的严重程度。因此，本节对第二组 11 位符合标准的患者睡眠呼吸声音信号数据分别进行 AHE 持续时间的判别，并将判别的结果与 AHI 分级指标的结果进行对比分析。采用方法为本文第三章所训练好的模型自动检测该 11 位患者整夜睡眠呼吸声音

信号的 AHE 总持续时间，并计算各患者占比的 S 值。表 4.6 和 4.7 给出了 11 位患者的 PSG 诊断和本次识别的实验 S 值诊断 OSA 严重程度（S 值诊断范围参照 4.2.2 小节中的表 4.4）的对比图。图 4.3 是表 4.6 中确定不同 OSA 严重程度的比例 S 值（图下部分）对比 AHI 值（图上部分）的结果图。

表 4.6 传统 AHI 值与声音信号 S 值诊断结果对比

患者编号	性别	S值大小	S值诊断	AHI值	AHI值诊断
01	男	0.002	正常	2.82	正常
02	女	0.073	轻度	3.19	正常
03	男	0.087	中度	13.52	轻度
04	女	0.120	中度	14.97	轻度
05	男	0.112	中度	21.45	中度
06	男	0.164	中度	23.56	中度
07	男	0.192	重度	29.33	中度
08	女	0.281	重度	41.72	重度
09	男	0.323	重度	49.77	重度
10	男	0.514	重度	54.64	重度
11	男	0.552	重度	64.49	重度

表 4.7 传统 AHI 值与声音信号 S 值诊断准确性对比

参数	正常	轻度OSA	中度OSA	重度OSA
数量（/人）	2	2	3	4
AHI值（/次）	AHI<5	5≤AHI<15	15≤AHI<30	AHI≥30
S值（百分比）	S<0.023	0.023≤S<0.080	0.080≤S<0.178	S≥0.178
S值对比AHI值诊断正确（/人）	1	0	2	4
S值对比AHI值诊断严重程度	50.0%	0.0%	66.6%	100%

表 4.7 中显示了对 11 例疑似患有 OSA 的患者进行了 PSG 诊断，并最终按照 AHI 参数值分类，随后进行实验参数 S 值的判定，并比较了 S 值判定结果对比 AHI 值分类的准确率。




图 4.3 AHI 值与 S 值诊断分布对比

通过对比 AHI 评估的结果，表 4.6 和表 4.7 的分析表明，本实验的诊断方法在重度 OSA 患者的判定上表现良好，效果显著。而在 OSA 症状较轻的患者中，诊断结果出现了误差。针对这种误差，本次实验将其具体值进行可视化，从图 4.3 中（图中三条紫色虚线代表 AHI 值和 S 值四种严重程度的分界线）的 S 值与 AHI 指数判断严重程度的趋势看，实验结果与 AHI 指标的判定趋势基本一致。图中的四个橙色点代表了与 AHI 评估对比时判定错误的类别，尽管存在误差，但从四种严重程度范围的数值来看，误差相对较小。这些误差主要出现在两种严重程度的边界上。例如，患者编号 03 在 AHI 诊断中被判定为轻度 OSA，但其真实 AHI 值接近中度的边缘，而实验方法则将其诊断为中度边缘，进而判定为中度 OSA。

4.2.4 基于睡眠呼吸声音的 S 值有效性分析

由 4.2.3 小节的实验结果可知，模型在诊断 OSA 严重程度方面表现出良好的准确率，但与 PSG 诊断的 AHE 持续总时间相比，仍需进一步验证。因此，本小节的目标是将模型诊断与 PSG 诊断的 AHE 总持续时间结果进行对比分析，并验证 11 例患者睡眠呼吸声信号的诊断结果 S 值与 PSG 诊断结果 S 值之间的误差，以此进一步评估睡眠呼吸声音信号在诊断 OSA 严重程度方面的有效性。

图 4.4 展示了患者声音信号与 PSG 诊断的结果 S 值在不同严重程度 OSA 上的对比情况。图 4.5 则为患者的综合对比趋势情况。




图 4.4 声音信号与 PSG 诊断结果对比




图 4.5 声音信号与 PSG 诊断结果对比趋势

在图 4.4 中，首先根据 PSG 所检测结果将 OSA 患者分为正常组（左上）、轻度组（右上）、中度组（左下）和重度组（右下）。其次，对每组患者进行

两次计算：一次是根据 PSG 诊断结果检测到的 S 值（蓝色线），另一次是根据睡眠呼吸声信号计算出的 S 值（橙色线）。图中横坐标表示患者对应的编号，纵坐标表示患者对应的两种诊断结果 S 值大小。图 4.5 为四组人群的综合趋势对比情况。在图 4.5 中，患者编号按 PSG 诊断的严重程度依次递增排序，以观察两种诊断方法在诊断结果上的整体趋势对比情况。

综上，从图 4.4 和图 4.5 可以看出，随着症状由轻到重的逐渐增加，睡眠呼吸声音信号对比 PSG 之间诊断的 S 值在准确率和相关性上面也更加接近。

4.3 实验结果分析

本章实验分为两个阶段：第一阶段：分析了 AHE 持续时间在 OSA 诊断及严重程度的有效性。实验结果表明，AHE 的持续时间与 OSA 的严重程度高度相关，为后续更为精准和全面的 OSA 分级提供了重要参考。第二阶段实验一：本阶段聚焦于睡眠呼吸声音信号，采用第三章训练出的模型对 AHE 持续时间进行识别，并建立相关 AHE 参数。对比 AHI 值诊断结果，在重度 OSA 患者中，分级准确率表现良好，但对于症状较轻的患者，准确率尚需进一步优化和改进。第二阶段实验二：提取了同一批患者的 PSG 检测数据中的 AHE 持续时间，并通过本文所建立的时间占比公式（公式 4.2）进行计算，得出对应的 S 值。同时，实验过程当中也提取了睡眠呼吸声音信号并计算相应的 S 值。通过将这两者的 S 值进行对比，实验结果显示了良好的相关性。这一系列实验为进一步提升 OSA 的识别准确性和分级提供了有力的数据支持。存在不足如下：

（1）数据采集环境

本文实验的目的是通过分析睡眠呼吸声音信号来诊断患者的 OSA 严重程度。实验环境设在医院的一个多床铺集中房间，检测过程中难免会受到其他床位患者的干扰信号影响，这些干扰信号的类型和数量较为复杂。此外，许多患者是首次进行此类检测，可能会出现适应不良或隔夜现象，导致结果的准确性受限。由于实验条件有限，无法支持多晚连续监测，因此识别率可能会受到一定程度的影响。

（2）患者样本量

由于受限于符合标准的患者睡眠呼吸声音信号的数据较少，本章仅使用 11 例进行评估，并且 OSA 严重程度的类别也不够均匀，故效果可能不达理想，后

续还需补充大量样本进行验证。

4.4 讨论

本文探索了一种基于呼吸信号检测 OSA 的新方法。在本章中，通过分析睡眠呼吸声音信号中检测到的 AHE 总持续时间与总睡眠时间的比值，验证该比值对 OSA 严重程度分类的可行性。研究结果表明，睡眠呼吸声音诊断出的 S 值与 PSG 诊断的 AHI 值及 S 值都有着较好的相关性，表明仅利用睡眠呼吸声音信号并结合本章设计的新量化参数，能够有效实现 OSA 的诊断与分级。

相比较传统的各种 OSA 检测信号，睡眠呼吸声音信号作为一种非侵入性且易于收集的信号，展现出较大的潜力。该信号的收集过程不会干扰睡眠过程，因此具有较高的家庭应用前景，能够为家庭诊断提供便捷的解决方案。

在评估 OSA 严重程度的参数指标方面。到目前为止，AHI 仍然是 PSG 监测数据中最常用的参数。它一直是诊断和判断 OSA 严重程度的传统评分方法，但不能全面反映 OSA 的临床表现和远期预后。本实验方法采用 AHE 持续时间来诊断 OSA，并取得了较好的效果，说明 AHE 持续时间与 OSA 严重程度之间存在相关性。但由于仍是与 AHI 进行比较，因此存在一定的局限性。本文将明确指出 S 值与 AHI 之间的相似性，并承认这可能会影响实验中的比较。但本文将强调 S 值的独特性及其在 AHE 持续时间上的优势，为今后进一步完善 S 值奠定基础，以期为 OSA 评估提供更准确、更灵敏的指标，开发出简易诊断设备（针对睡眠呼吸声音信号）。该方法有望补充新的相关 OSA 诊断指标参数，为今后进一步准确全面评价 OSA 提供重要参考。

从本章研究结果可以看出，该方法对重度 OSA 患者的诊断能力较强，准确率基本和 PSG 检测一致。此外，实验结果还可以推测，在更严重的情况下，这种改善可能与夜间睡眠期间发生的每次 AHE 的长度差异有关。这种差异值得进一步考虑和分析。

4.5 本章小结

本章基于符合 PSG 检测标准的 225 例患者数据和符合标准睡眠呼吸声音信号的 11 例患者数据，结合第三章训练好的 FM-DS-U-Net 网络模型进行评估与预

测，旨在检测信号中的 AHE 持续时间。进一步提出了一种以 AHE 持续时间占总睡眠时间比例（参数 S ）进行 OSA 诊断和分级的方法。本章详细介绍了 AHE 持续时间的提取流程以及实验参数的设计思路。同时经过多种实验的设计和验证，结果表明，本章提出的 AHE 相关参数 S 值能在睡眠呼吸声音信号中准确识别提取，并可以应用在 OSA 严重程度的评估上。最后，在实验分析和讨论部分也对实验过程和结果中存在的不足进行了深入探讨。本章的研究为进一步提高 OSA 诊断准确性和分级提供了有力的数据支持。

第 5 章 总结与展望

5.1 总结

本文通过分析和研究非接触式监测下的睡眠呼吸声音信号，从信号采集、预处理、降噪滤波、网络架构设计与模型优化、OSA 评估参数的建立，以及定性和精确诊断等多个方面，提出了一种基于呼吸信号的 OSA 识别研究。本文的主要工作内容如下：

（1）在数据库的有效建立过程中，与相关合作医院共同采集了实验所需的患者信号数据，并进行了科学规范的 AHE 标注。针对睡眠呼吸声音信号是否能满足临床环境下识别和诊断 OSA 的要求，本文对原始采集到的信号数据进行了数据清洗，剔除了不符合标准的信号数据。针对整晚睡眠呼吸声音信号序列较长，导致模型计算复杂度较高的问题，本文基于所采集到的患者数据信号特征，对信号进行了滑动窗口（窗口大小为 2 分钟）切割，将单个整晚监测的信号大样本划分为多个连续的 2 分钟的小样本。此举旨在提高信号数据处理的效率，并使其更符合临床实际应用及后续工作的需要。

（2）在睡眠呼吸声音信号的高质量滤波去噪方面，提出了一种基于多技术融合的滤波降噪算法，能够对含有干扰因素的原始睡眠呼吸声音信号实现良好的去噪声，为后续 OSA 的精确识别与诊断奠定基础。首先采用了几种传统降噪算法对信号数据进行了分析和实现，发现并不能达到实验所需的实际效果。其次，针对传统算法在睡眠呼吸声音信号中降噪的不足点和观察所采集的信号特征进行总结，结合了预加重、分帧加窗、小波变换和非线性变换相关技术，设计了一个多技术融合的平滑去噪算法。该算法首先采用高通数字滤波进行预加重，去除低频噪声，突出呼吸信号的高频变化。在此基础上，应用非线性变换增强振幅部分，提升对 AHE 发生的前后呼吸状态等异常事件的敏感度。其次，利用小波变换进行信号分解和噪声去除，使用软阈值处理有效去除噪声，并通过小波逆变换重构信号。最后，应用汉明窗平滑处理，去除快速波动或随机噪声，使信号更加稳定可靠。实验结果表明，所设计的滤波降噪算法能较好去除睡眠呼吸信号中的噪声，增强关键特征，确保了后续 OSA 相关分析的准确性和

有效性。

(3) 在睡眠呼吸声音信号的分割模型方面, 提出了 FM-DS-U-Net 网络, 能够检测出睡眠呼吸声音信号的关键波形, 实现 AHE 的准确分割。针对现有研究中的模型计算复杂、参数量大的问题, 引入了深度可分离卷积, 结合残差结构设计了一种深度可分离残差模块, 大大降低模型参数量的同时增加了模型的训练效果。针对现有模型识别精度问题, 引入了轻量化的 CBAM 注意力机制和反馈机制, 提升睡眠呼吸声音信号的特征提取能力和分割效果。实验结果表明, 模型在睡眠呼吸声音信号分割上具有较好的分割效果, 对于临床中的 OSA 识别和诊断分析具有一定的辅助作用。最后还调整了不同误差容忍度对 OSA 相关识别精度的影响, 并对实验结果进行了深入分析。

(4) 在睡眠呼吸声音信号的分级诊断方面, 提出了新的量化参数 S 值, 即 AHE 持续时间占总睡眠时间比值。针对 S 值的可靠性问题, 采集了 225 例患者的数据进行实验, 证实了 S 值在 OSA 诊断上的有效性。针对睡眠呼吸声音信号提取 S 值的问题, 使用本文所训练出的模型进行检测提取, 同时采用了 11 例患者, 以每人每次作为一个单独样本按照实验设计方法进行检测提取 S 值。实验结果表明, 睡眠呼吸声音信号中提取的 S 值具有较好的分级诊断效果。最后, 通过对实验结果进行深入分析和讨论, 本章所提出的 S 值可对当前评估 OSA 严重程度的相关参数提供新的思路, 同时对 OSA 家庭化识别设备的实现具有重要意义。

综上, 本研究针对睡眠呼吸声音信号在 OSA 诊断与分级中的研究, 提出了一系列创新方法并取得显著成果。通过对信号进行高质量降噪滤波、分割及 AHE 参数识别研究和应用实验, 证实了基于呼吸信号的方法有效性, 能够用于 OSA 的识别与分类。

5.2 展望

本文研究的最终目的是对患者的睡眠呼吸声音进行高质量滤波降噪和 AHE 精准分割, 识别出正确的 AHE 持续时间, 并以提出的新量化参数进行相应换算出具体的值, 评估出是否患有 OSA 及其严重程度, 以达到进一步完善 OSA 的简易诊断方法以及为临床提供 OSA 初步诊断和自动干预诊断的技术手段, 但总结现有的工作, 本文还存在一些工作有待完善:

(1) 在信号数据采集方面, 本文所采集的数据主要来自 50 岁以上的患者。由于样本量较为有限, 尚不足以对不同年龄类型的患者进行多样化的诊断分析。后续的研究可以通过增加样本量, 并根据患者的个体差异进行分类处理与分析, 从而实现更加精准和全面的 OSA 识别与诊断。

(2) 在睡眠呼吸声音信号的模型设计方面, 由于睡眠声音信号波形的多样性, 以及不同严重程度的 OSA 患者产生的睡眠呼吸声音波形差异, 未来的研究可以考虑为不同严重程度的 OSA 患者 (如轻度、中度、重度等) 人群设计专门的模型, 以更好地适应各类个体差异, 从而提高诊断的精确度。

(3) 针对本文提出的 AHE 持续时间占总睡眠时间比值 S , 其严重程度范围值目前依据本文实验结果 (225 例数据) 进行定义。尽管在该数据集上 S 值表现出良好的分级能力, 但由于缺乏大量样本的验证, 科学规范的严重程度分级范围尚不明确。未来的研究可以考虑将 S 值与传统的 AHI 值结合, 作为评估 OSA 严重程度的补充, 两者的结合有望为 OSA 的诊断提供更加全面和精准的评估, 推动 OSA 研究的进一步发展。

致 谢

在本论文即将完成之际，我衷心感谢在这一过程中给予我帮助和支持的所有人。

感谢我的导师夏老师，感谢您在我整个研究过程中给予的悉心指导和无私帮助。您的严谨学术态度、深厚的专业知识以及无微不至的关怀，使我在学术探索的道路上受益良多。在遇到困难和疑惑时，您总是耐心地为我解答，指引我前行。您不仅教会了我如何进行科学研究，更教会了我如何思考问题、解决问题。这些宝贵的经验将伴随我一生。

感谢南昌大学为我提供了这样一个宽广的平台，让我有机会在这里汲取知识、锻炼能力。在南昌大学的学习和生活中，我收获了丰富的学术经验，并且结识了许多优秀的同学和老师，这一切都为我今后的发展奠定了坚实的基础。

感谢南昌大学第二附属医院的王医生及各位医生，感谢你们在我的研究过程中提供的帮助和支持。在研究期间，你们不仅给予了我宝贵的建议，还提供了实际的数据和资源支持，使我能够顺利完成相关研究工作。

感谢室友和实验室各位同门，在我研究生涯的每一个阶段，你们都陪伴在我左右。无论是在学习上，还是在生活中，你们的支持与鼓励让我感受到无比的温暖。

感谢我的父母，感谢你们一直以来对我不懈的支持与无条件的爱。你们的理解和鼓励，是我能够专心完成学业的坚强后盾。无论我身处何方，你们始终是我最大的动力源泉。

感谢我的女友，在这段时间里，你是我最大的支持者。你的关心、陪伴和理解让我在忙碌的研究过程中找到了心灵的寄托。。

最后，感谢我自己。在这段求学旅程中，我也在不断超越自己、克服困难、不断学习与成长。虽然过程艰辛，但每一步都让我更加坚定了追求知识与真理的决心。

路漫漫其修远兮，回望过去，感慨万千，展望未来，我将继续努力，不忘初心，勇敢前行！

参考文献

- [1] Robert, Sebastian, Büttner, et al. Reasoning under uncertainty: Towards collaborative interactive machine learning(Book Chapter)[J]. Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics), 2016, Vol. 9605(1): 357-376.
- [2] Olga M, Nicolás G M, Josep M, et al. International consensus document on obstructive sleep apnea[J]. Archivos deBronconeumología, 2022, Vol. 58(1): 52-68.
- [3] Lloberes P, Joaquín DuránCantolla, Miguel Ángel MartínezGarcía, et al. Diagnosis and treatment of sleep apnea-hypopnea syndrome. Spanish Society of Pulmonology and Thoracic Surgery[J]. Archivos De Bronconeumología, 2011, 47(3): 143-156.
- [4] Benjafield AV, Ayas NT, Eastwood PR, et al. Estimation of the global prevalence and burden of obstructive sleep apnoea: a literature-based analysis. Lancet Respir Med. 2019 Aug; 7(8): 687-698.
- [5] Hong Z, Ou Q, Cheng Y, et al. Cardiac imageology changes in patients with mild obstructive sleep apnea without cardiovascular disease [J] . Sleep Breath, 2022, 26(2): 595-604.
- [6] Raptis DG, Sinani O, Rapti GG, et al. Clinically silent small vessel disease of the brain in patients with obstructive sleep apnea hypopnea syndrome [J] . Diagnostics, 2021, 11(9): 1673.
- [7] Tarasiuk A, Greenberg-Dotan S, Simon T, et al. Low socioeconomic status is a risk factor for cardiovascular disease among adult obstructive sleep apnea syndrome patients requiring treatment. Chest. 2006; 130: 766-773.
- [8] Butt M, Dwivedi G, Khair O, et al. Obstructive sleep apnea and cardiovascular disease[J]. International journal of cardiology, 2010, 139(1): 7-16.
- [9] Kargar B, Zamanian Z, Hosseinabadi MB, et al. Understanding the role of oxidative stress in the incidence of metabolic syndrome and obstructive sleep apnea [J] . BMC Endocr Disord, 2021, 21(1): 77.
- [10] Koo DL, Kim H-R, Nam H. Moderate to severe obstructive sleep apnea during REM sleep as a predictor of metabolic syndrome in a Korean population. Sleep Breath. 2020; 24: 1-8.
- [11] Arzt M,Young I, Finn L, et al. Association of sleep-disordered breathing and the occurrence of stroke. Am J Respir Crit CareMed. 2005; 172: 1447-1451.
- [12] Rolón R E, Gareis I E, Larrateguy L D, et al. Automatic scoring of apnea and hypopnea events using blood oxygen saturation signals [J]. Biomedical Signal Processing and Control, 2020, 62: 102062.
- [13] Berry RB, Budhiraja R, Gottlieb DJ, et al. Rules for scoring respiratory events in sleep: update of the 2007 AASM manual for the scoring of sleep and associated events.

- Deliberations of the sleep apnea Definitions Task force of the American Academy of Sleep Medicine. *J Clin Sleep Med*. 2012, 8: 597–619.
- [14] Thornton A T, Singh P, Ruehland W R, et al. AASM Criteria for Scoring Respiratory Events: Interaction between Apnea Sensor and Hypopnea Definition[J]. *Sleep*, 2012, Vol. 35(3): 425-432.
- [15] American Academy of Sleep Medicine International classification of sleep disorders, 3rd edn. American Academy of Sleep Medicine, Darien. 2014.
- [16] Butler MP, Emch JT, Rueschman M, et al. Apnea-hypopnea event duration predicts mortality in men and women in the Sleep Heart Health Study [J]. *Am J Respir Crit Care Med*, 2019, 199(7): 903-912.
- [17] Zhan X, Fang F, Wu C, et al. A Retrospective Study to Compare the Use of the Mean Apnea-Hypopnea Duration and the Apnea-Hypopnea Index with Blood Oxygenation and Sleep Patterns in Patients with Obstructive Sleep Apnea Diagnosed by Polysomnography. *Med Sci Monit*. 2018 Mar 31; 24: 1887-1893.
- [18] Kainulainen S, Töyräs J, Oksenberg A, et al. Severity of desaturations reflects OSAHS-related daytime sleepiness better than AHI [J]. *J Clin Sleep Med*, 2019, 15(8): 1135-1142.
- [19] Huijun Yue, Yu Lin, Yitao Wu, et al. Deep Learning for Diagnosis and Classification of Obstructive Sleep Apnea: A Nasal Airflow-Based Multi-Resolution Residual Network[J]. *Nature and science of sleep*, 2021, Vol. 13: 361-373.
- [20] Jin J Y, Sanchez-Sinencio E. A Home Sleep Apnea Screening Device With Time Domain Signal Processing and Autonomous Scoring Capability [J]. *IEEE Transactions on Biomedical Circuits and Systems*, 2015, 9(1): 96-104.
- [21] Barroso-García V, Gutiérrez-Tobal G C, Gozal D, et al. Wavelet analysis of overnight airflow to detect obstructive sleep apnea in children [J]. *Sensors*, 2021, 21(4): 1491.
- [22] Garde A, Xenia H, Dehkordi P, et al. Pediatric pulse oximetry-based OSA screening at different thresholds of the apnea-hypopnea index with an expression of uncertainty for inconclusive classifications[J]. *Sleep Med*, 2019(60): 45-52.
- [23] Fernando Vaquerizo-Villar, Daniel Alvarez, Leila Kheirandish-Gozal, et al. A convolutional neural network architecture to enhance oximetry ability to diagnose pediatric obstructive sleep apnea[J]. *IEEE journal of biomedical and health informatics*, 2021, 25(8): 1.
- [24] Alarez D, Hornero R, Abasolo D, et al. Nonlinear characteristics of blood oxygen saturation from nocturnal oximetry for obstructive sleep apnoea detection [J]. *Physiological Measurement*, 2006, 27(4): 399-412.
- [25] Jong-Uk Park, Hyo-Ki Lee, Junghun Lee, et al. Automatic classification of apnea/hypopnea events through sleep/wake states and severity of SDB from a pulse oximeter. [J]. *Physiological Measurement*, 2015, 36(9): 2009-2025.
- [26] Li K, Pan W, Li Y, et al. A method to detect sleep apnea based on deep neural network and hidden Markov model using single-lead ECG signal[J]. *Neurocomputing*, 2018, 294: 94-101.

- [27] Haifa AlmutairiCA1,Ghulam Mubashar Hassan,Amitava Datta. Classification of Obstructive Sleep Apnoea from single-lead ECG signals using convolutional neural and Long Short Term Memory networks[J]. Biomedical Signal Processing and Control, 2021, 69: 102906.
- [28] Sharan R V, CAa B, et al. End-to-End Sleep Apnea Detection Using Single-Lead ECG Signal and 1-D Residual Neural Networks[J]. Journal of Medical and Biological Engineering, 2021, 41(5): 758-766.
- [29] Jarchi D, Andreu-Perez J, Kiani M, et al. Recognition of patient groups with sleep related disorders using bio-signal processing and deep learning [J]. Sensors, 2020, 20(9): 2594.
- [30] Bello S A, Alqasemi U. Computer Aided Detection of Obstructive Sleep Apneafrom EEG Signals [J]. Available at SSRN 3890660, 2021.
- [31] Suvasish S,Arnab B,Shaikh A F. Automatic detection of sleep apnea events based on inter-band energy ratio obtained from multi-band EEG signal(Article)[J]. Healthcare Technology Letters, 2019, 6(3): 82-86.
- [32] Wang K-J, Chen K-H, Huang S-H, et al. A prognosis tool based on fuzzy anthropometric and questionnaire data for obstructive sleep apnea severity [J]. Journal of medical systems, 2016, 40(4): 1-12.
- [33] 吕兴凤, 李金宝. 一种利用随机森林方法检测睡眠呼吸暂停的研究[J]. 北京邮电大学学报, 2020, 43: 64-70.
- [34] Qian, Kun, Janott, et al. Classification of the Excitation Location of Snore Sounds in the Upper Airway by Acoustic Multifeature Analysis[J]. IEEE Transactions on Biomedical Engineering, 2017, 64(8): 1731-1741.
- [35] Sebastian A, Cistuli PA, Cohen G, et al. Association of snoring characteristics with predominant site of collapse of upper airway it obstructive sleep apnea patients. Sleep. 2021: 44.
- [36] Mei Wei, Jianqun Du, Xiaoyu Wang, et al. Voice disorders in severe obstructive sleep apnea patients and comparison of two acoustic analysis software programs: MDVP and Praat[J]. Sleep and Breathing, 2021, 25(1): 433-439.
- [37] 侯丽敏, 潘强, 张新鹏. 基于鼾声声学特性的上气道阻塞部位分类[J].复旦学报(自然科学版), 2020, 59(05): 523-530.
- [38] Su Geun Kim, Sung-Woo Cho, Jeong-Whun Kim. Definition of the snoring episode index based on the analyses of snoring parameters and the apnea hypopnea index[J]. Scientific Reports, 2022, 12(1): 1-6.
- [39] 李馨. 基于鼾声时频分析的 OSAHS 诊断[D]. 大连理工大学, 2014.
- [40] Jing Luo. A novel deep feature transfer-based OSA detection method using sleep sound signals [J]. Physiological Measurement, 2020, 41(7): 75-84.
- [41] Siyi Cheng, Chao Wang, Keqiang Yue, et al. Automated sleep apnea detection in snoring signal using long short-term memory neural networks [J]. Biomedical Signal Processing and Control, 2022, 71: 103238.
- [42] Zhao S, Fang Y, Wang W, et al. Analysis of Sleeping Respiratory Signal Utilizing

- Frequency-Energy Features [C], 2022 5th International Conference on Information Communication and Signal Processing (ICICSP). IEEE, 2022: 86-90.
- [43] Yujun Song, Xiaoran Sun, Li Ding, et al. AHI estimation of OSAHS patients based on snoring classification and fusion model [J]. American Journal of Otolaryngology, 2023, 44(5): 103964.
- [44] Lim, Seung Ju, Jang, et al. Classification of snoring sound based on a recurrent neural network [J]. Expert Systems with Applications, 2019, 123: 237-245.
- [45] Tan Loc Nguyen, Yonggwan Won. Sleep snoring detection using multi-layer neural networks [J]. Bio-Medical Materials and Engineering, 2015, 26(1): S1749-S1755.
- [46] Jiali Xie, Pedro Fonseca, Johannes van Dijk, et al. Assessment of obstructive sleep apnea severity using audio-based snoring features [J]. Biomedical Signal Processing and Control, 2023, 86: 104942.
- [47] Shota Hayashi, Meiyo Tamaoka, Tomoya Tateishi, et al. A New Feature with the Potential to Detect the Severity of Obstructive Sleep Apnoea via Snoring Sound Analysis [J]. International journal of environmental research and public health, 2020, 17(8): 2951.
- [48] 杨弋, 秦永, 黄魏宁, 等. 阻塞性睡眠呼吸暂停低通气综合征患者鼾声的声学特征研究 [J]. 临床耳鼻咽喉头颈外科杂志, 2012, 26(8): 360-363.
- [49] Kim T, Kim J-W, Lee K. Detection of sleep disordered breathing severity using acoustic biomarker and machine learning techniques [J]. Biomedical engineering online, 2018, 17(1): 1-19.
- [50] Sinem Akyol, Muhammed Yildirim, Bilal Alatas. Multi-feature fusion and improved BO and IGWO metaheuristics based models for automatically diagnosing the sleep disorders from sleep sounds[J]. Computers in biology and medicine, 2023, 157: 106768.
- [51] Romero HE, Ma N, Brown G, et al. Acoustic Screening for Obstructive Sleep Apnea in Home Environments Based on Deep Neural Networks[J]. IEEE journal of biomedical and health informatics, 2022, 26(7): 2941-2950.
- [52] Asli B, Selen B, Murat T. The relationship between the duration of obstructive respiratory events and outcomes of multilevel upper airway surgery in patients with obstructive sleep apnea[J]. EUROPEAN ARCHIVES OF OTO-RHINO-LARYNGOLOGY, 2016, 273(9): 2651-2657.
- [53] Zamzil A A, Jamalludin A R, Abdul H M, et al. Association Between Severity of Obstructive Sleep Apnea and Number and Sites of Upper Airway Operations With Surgery Complications[J]. JAMA otolaryngology-- head & neck surgery, 2017, 143(3): 239-246.
- [54] Sarac S, Afsar GC. Effect of mean apnea-hypopnea duration in patients with obstructive sleep apnea on clinical and polysomnography parameter. Sleep Breath. 2020 Mar; 24(1): 77-81.
- [55] Butler, Matthew P, Emch, et al. Apnea-Hypopnea Event Duration Predicts Mortality in Men and Women in the Sleep Heart Health Study.[J]. American Journal of Respiratory & Critical Care Medicine, 2019, 199(7): 903-912.

- [56] Zinchuk AV, Jeon S, Koo BB, et al. Polysomnographic phenotypes and their cardiovascular implications in obstructive sleep apnoea [J]. *Thorax*, 2018, 73(5):472-480.
- [57] 马长秀. 呼吸暂停低通气持续时间在阻塞性睡眠呼吸暂停症状及严重程度评价中的意义[D]. 安徽医科大学, 2021.
- [58] Weigen Cheng, Cheng Xu, Fen Wang, et al. Application study of apnea-hypopnea duration for assessing adult obstructive sleep apnea[J]. *Technology and health care : official journal of the European Society for Engineering and Medicine*, 2024, 32(5): 1-15.
- [59] Benjafield, AV (Benjafield, Adam V.), et al. Estimation of the global prevalence and burden of obstructive sleep apnoea: a literature-based analysis(Article)[J]. *The Lancet Respiratory Medicine*, 2019, 7(8): 687-698.
- [60] Koutsourelakis I, Georgouloupoulos G, Perraki E, et al. Randomised trial of nasal surgery for fixed nasal obstruction in obstructive sleep apnoea[J]. *European Respiratory Journal*, 2008, 31(1): 110-117.
- [61] de Chazal P, Sutherland K, Cistulli PA. Advanced polysomnographic analysis for OSA: A pathway to personalized management? *Respirology*. 2020 Mar; 25(3): 251-258.
- [62] 白燕燕,白帆,张少哲,等. 谱减法在语音信号去噪上的应用[J]. *家庭影院技术*, 2024, 328(2): 59-61.
- [63] 张秀秀. 基于维纳滤波算法的研究和分析[J]. *长治学院学报*, 2024, 41(5): 16-18.
- [64] Terry M. Jones, Meau-Shin Ho, John E. Earis, et al. Acoustic parameters of snoring sound to assess the effectiveness of the Müller Manoeuvre in predicting surgical outcome[J]. *Auris Nasus Larynx*, 2006, 33(4): 409-416.
- [65] IEEE transactions on acoustics, speech, and signal processing[J]. *Signal Processing*, 1982, 4(4): 345-346.
- [66] 孙文彦, 熊璋, 韩军, 等. 语音信号实时传输中的动态变长分帧算法[J]. *通信学报*, 2001, (7): 80-87.
- [67] Olaf Ronneberger, Philipp Fischer, Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation[J]. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, 2015, 9351: 234-241.
- [68] Huimin Huang, Lanfen Lin, Ruofeng Tong, et al. UNet 3+: A Full-Scale Connected UNet for Medical Image Segmentation[J]. 2020,.
- [69] Woo, SanghyunCAa, Park, et al. CBAM: Convolutional block attention module[J]. *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 2018, 11211: 3-19.
- [70] Andrew G. Howard, Menglong Zhu, Bo Chen, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications [J]. 2017, arXiv preprint: 1704.04861.
- [71] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016: 770-778.
- [72] Zhan X, Fang F, Wu C, et al. A Retrospective Study to Compare the Use of the Mean Apnea-Hypopnea Duration and the Apnea-Hypopnea Index with Blood Oxygenation and

参考文献

Sleep Patterns in Patients with Obstructive Sleep Apnea Diagnosed by Polysomnography.
Med Sci Monit. 2018 Mar 31; 24: 1887-1893.

攻读学位期间的研究成果

已发表论文：

1. Weigen Cheng, Cheng Xu, Fen Wang, et al. Application study of apnea-hypopnea duration for assessing adult obstructive sleep apnea[J]. Technology and health care : official journal of the European Society for Engineering and Medicine, 2024, Vol.32(5): 1-15.

公布发明专利：

1. 一种判断阻塞型睡眠呼吸暂停综合症严重程度方法及装置，2023-12-26, 中国, CN117860197A.
2. 一种用于舌压测量的装置及量化评估方法，2024-11-05, 中国 CN118892307A.